

INSTITUTO FEDERAL DE EDUCAÇÃO CIÊNCIA E TECNOLOGIA DE MINAS  
GERAIS – *CAMPUS* BAMBUÍ  
BACHARELADO EM ENGENHARIA DE COMPUTAÇÃO

Carlos Eduardo de Sousa Faria

**ALGORITMO GENÉTICO COMPACTO E MODELO DE  
MARKOWITZ APLICADOS À OTIMIZAÇÃO DE  
PORTFÓLIO EM CARTEIRAS DE CRIPTOMOEDAS**

CARLOS EDUARDO DE SOUSA FARIA

**ALGORITMO GENÉTICO COMPACTO E MODELO DE  
MARKOWITZ APLICADOS À OTIMIZAÇÃO DE  
PORTFÓLIO EM CARTEIRAS DE CRIPTOMOEDAS**

Trabalho de conclusão de curso apresentado  
ao Curso de Bacharelado em Engenharia de  
Computação do Instituto Federal de Educa-  
ção Ciência e Tecnologia de Minas Gerais –  
*Campus* Bambuí como requisito parcial para  
obtenção do grau de Bacharel em Engenharia  
de Computação.

Orientador: Prof. Dr. Cíniro Aparecido  
Leite Nametala

Bambuí - MG

2023

Catálogo na Fonte Biblioteca IFMG - Campus Bambuí

F224a Faria, Carlos Eduardo de Sousa.  
Algoritmo genético compacto e modelo de Markowitz aplicados à  
otimização de portfólio em carteiras de criptomoedas. / Carlos Eduardo  
de Sousa Faria. – 2023.  
59 f. : il. ; color.

Orientador: Ciniro Aparecido Leite Nametala.  
Trabalho de Conclusão de Curso (graduação) - Instituto Federal de  
Educação, Ciência e Tecnologia de Minas Gerais – Campus Bambuí,  
MG, Curso Bacharelado em Engenharia de Computação, 2023.

1. Criptomoeda. 2. Carteira de investimento. 3. Otimização. I.  
Nametala, Ciniro Aparecido Leite. II. Instituto Federal de Educação,  
Ciência e Tecnologia de Minas Gerais – Campus Bambuí, MG. III.  
Título.

CDD 005.4

Elaborada por Douglas Bernardes de Castro- CRB-6/2802

Carlos Eduardo de Sousa Faria

## ALGORITMO GENÉTICO COMPACTO E MODELO DE MARKOWITZ APLICADOS À OTIMIZAÇÃO DE PORTFÓLIO EM CARTEIRAS DE CRIPTOMOEDAS

Trabalho de conclusão de curso apresentado ao Curso de Bacharelado em Engenharia de Computação do Instituto Federal de Educação Ciência e Tecnologia de Minas Gerais – *Campus Bambuí* como requisito parcial para obtenção do grau de Bacharel em Engenharia de Computação.

Aprovado em 11 de dezembro de 2023 pela banca examinadora:

Prof. Dr. Ciniro Aparecido Leite Nametala – IFMG – *Campus Bambuí* – (Orientador)  
Prof. Mr. Itagildo Edmar Garbazza – IFMG – *Campus Bambuí*  
Prof. Mr. Samuel Pereira Dias – IFMG – *Campus Bambuí*



Documento assinado eletronicamente por **Ciniro Aparecido Leite Nametala, Professor**, em 11/12/2023, às 10:47, conforme Decreto nº 10.543, de 13 de novembro de 2020.



Documento assinado eletronicamente por **Itagildo Edmar Garbazza, Professor**, em 11/12/2023, às 10:47, conforme Decreto nº 10.543, de 13 de novembro de 2020.



Documento assinado eletronicamente por **Samuel Pereira Dias, Professor**, em 11/12/2023, às 10:47, conforme Decreto nº 10.543, de 13 de novembro de 2020.



A autenticidade do documento pode ser conferida no site <https://sei.ifmg.edu.br/consultadocs> informando o código verificador **1758509** e o código CRC **8A8E219A**.

*Dedico este trabalho à minha mãe, Soane Cecília de Sousa, e à minha avó, Maria  
Veneranda Barbosa de Sousa.*

## AGRADECIMENTOS

Primeiramente, agradeço a Deus por conceder-me o dom da vida e manter-me perseverante, mesmo diante dos obstáculos encontrados ao longo da graduação.

À minha querida mãe, Soane Cecília de Sousa, expresso profundo agradecimento pelo apoio incondicional, compreensão e amor. Sua força e dedicação são minha fonte de inspiração.

Aos meus familiares e amigos, agradeço pelo apoio constante, carinho e presença. Sua importância é imensurável.

Ao meu orientador Ciniro Nametala, que conduziu o trabalho com maestria e comprometimento, agradeço pelos ensinamentos compartilhados, paciência e dedicação ao longo desses meses.

Aos demais professores que fizeram parte da minha formação acadêmica, meu sincero agradecimento. Cada um de vocês contribuiu significativamente para o meu aprendizado e crescimento.

Ao Instituto Federal de Educação, Ciência e Tecnologia de Minas Gerais, *Campus* Bambuí, meu agradecimento pela oferta de um ambiente propício ao aprendizado e desenvolvimento acadêmico.

Por fim, agradeço a todos que, de alguma forma, colaboraram para a realização deste trabalho, direta ou indiretamente.

*“A verdadeira sabedoria está em saber que você não sabe.”*  
*(Sócrates)*

## RESUMO

A seleção de carteiras de investimentos é uma tarefa complexa que envolve a escolha dos ativos que compõem um portfólio. No contexto das criptomoedas, essa atividade torna-se particularmente desafiadora devido à alta volatilidade e complexidade inerentes a esse mercado. Apesar dessas características, as criptomoedas têm ganhado uma crescente popularidade nos últimos anos, tornando-se uma opção de investimento atrativa para muitos. Neste cenário, identificou-se uma necessidade premente de abordar a otimização da seleção de carteiras de criptomoedas, explorando o potencial dos Algoritmos de Estimação de Distribuição (EDAs). O propósito fundamental deste trabalho é a implementação de um tipo de EDA chamado Algoritmo Genético Compacto, empregando a Teoria Moderna de Portfólio de Markowitz como base. O objetivo é a otimização da composição do portfólio de investimentos, enfocando a maximização dos retornos e a minimização dos riscos associados. Para alcançar essa finalidade, os preços de fechamento das criptomoedas selecionadas foram obtidos de maneira abrangente por meio da plataforma CoinGecko, cobrindo um período histórico de três anos (de 2020 a 2022) segmentados em três experimentos. Os resultados obtidos mostram que a técnica foi capaz de gerar bons resultados. Utilizando a métrica do índice Sharpe, a melhor carteira identificada pelo Algoritmo Genético Compacto, no conjunto de treino ficou classificada entre os 100 melhores retornos no conjunto de teste, durante os três experimentos conduzidos em um espaço de soluções contendo 1000 carteiras geradas.

**Palavras-chave:** Criptomoeda, Carteira de Investimento, Otimização, *Compact Genetic Algorithm*.



## ABSTRACT

The selection of investment portfolios is a complex task that involves choosing the assets that make up a portfolio. In the context of cryptocurrencies, this activity becomes particularly challenging due to the high volatility and complexity inherent in this market. Despite these characteristics, cryptocurrencies have gained increasing popularity in recent years, becoming an attractive investment option for many. In this scenario, there is a pressing need to address the optimization of cryptocurrency portfolio selection by exploring the potential of Estimation Distribution Algorithms (EDAs). The fundamental purpose of this work is to implement a type of EDA called Compact Genetic Algorithm, employing the Modern Portfolio Theory of Markowitz as a foundation. The goal is to optimize the composition of the investment portfolio, focusing on maximizing returns and minimizing associated risks. To achieve this, the closing prices of selected cryptocurrencies were comprehensively obtained through the CoinGecko platform, covering a historical period of three years (from 2020 to 2022) segmented into three experiments. The results obtained demonstrate that the technique was able to generate good results. Using the Sharpe ratio metric, the best portfolio identified by the Compact Genetic Algorithm in the training set ranked among the top 100 returns in the test set during the three experiments conducted in a solution space containing 1000 generated portfolios.

**Keywords:** Cryptocurrency, Investment Portfolio, Optimization, Compact Genetic Algorithm.

## LISTA DE FIGURAS

Figura 1 – Resultados da Pesquisa Eurex . . . . .	16
Figura 2 – Exemplo de <i>Blockchain</i> . . . . .	21
Figura 3 – Variação do preço do <i>Bitcoin</i> de 2016 a 2023 . . . . .	21
Figura 4 – Fronteira Eficiente . . . . .	27
Figura 5 – Representação de um indivíduo de uma população . . . . .	29
Figura 6 – Frequência relativa de citações das palavras chaves deste estudo . . . . .	33
Figura 7 – Frequência relativa de citações dos algoritmos empregados neste trabalho . . . . .	34
Figura 8 – Fluxograma de execução do projeto . . . . .	38
Figura 9 – Fluxograma do CGA . . . . .	41
Figura 10 – Ciclo regulador do projeto . . . . .	42
Figura 11 – Histórico do preço de fechamento do <i>Bitcoin</i> . . . . .	46
Figura 12 – Histórico do preço de fechamento 1 . . . . .	46
Figura 13 – Histórico do preço de fechamento 2 . . . . .	47
Figura 14 – Matriz de correção do Experimento 1 . . . . .	48
Figura 15 – Retorno médio e Desvio-padrão . . . . .	49
Figura 16 – Retorno percentual diário do BSV, XLM, LEO e USDT . . . . .	50
Figura 17 – Fronteira eficiente do Experimento 1 . . . . .	51
Figura 18 – Mapa de calor do vetor de probabilidade do Experimento 1 . . . . .	52
Figura 19 – Avaliação das carteiras . . . . .	54

## LISTA DE TABELAS

Tabela 1 – Etapas do Trabalho . . . . .	37
Tabela 2 – Divisão dos conjuntos de dados . . . . .	44
Tabela 3 – Criptomoedas selecionadas para os experimentos . . . . .	45
Tabela 4 – Preço de Fechamento: Conjunto de treino do Experimento 1 . . . . .	45
Tabela 5 – Retornos médios percentuais . . . . .	49
Tabela 6 – Resultados da otimização . . . . .	50
Tabela 7 – Distribuição dos pesos nas carteiras ótimas . . . . .	51
Tabela 8 – Estatísticas descritivas dos retornos das 1000 carteiras . . . . .	53

## LISTA DE ALGORITMOS

Algoritmo 1 – Pseudocódigo do CGA . . . . .	32
---	----

## LISTA DE ABREVIATURAS E SIGLAS

AG	Algoritmo Genético
AGC-D	Algoritmo Genético Compacto com Dominância
API	<i>Application Programming Interface</i> (Interface de Programação de Aplicação)
BRL	Real Brasileiro
BTC	<i>Bitcoin</i>
CE	Computação Evolucionária
CSV	<i>Comma-separated values</i>
DSR	<i>Design Science Research</i>
CGA	<i>Compact Genetic Algorithm</i> (Algoritmo Genético Compacto)
EDA	<i>Estimation Distribution Algorithm</i> (Algoritmos de Estimação de Distribuição)
IA	Inteligência Artificial

## SUMÁRIO

1	INTRODUÇÃO . . . . .	15
1.1	Objetivos . . . . .	16
1.1.1	<i>Objetivo Geral</i> . . . . .	16
1.1.2	<i>Objetivos Específicos</i> . . . . .	16
1.1.3	<i>Resultados Esperados</i> . . . . .	17
1.2	Justificativa . . . . .	17
1.3	Estrutura do Trabalho . . . . .	17
2	FUNDAMENTAÇÃO TEÓRICA . . . . .	19
2.1	O mercado das criptomoedas . . . . .	19
2.1.1	<i>Blockchain</i> . . . . .	20
2.1.2	<i>A volatilidade das criptomoedas</i> . . . . .	21
2.2	Seleção de carteira de investimento . . . . .	22
2.2.1	<i>Retorno</i> . . . . .	22
2.2.2	<i>Risco</i> . . . . .	23
2.2.3	<i>Covariância</i> . . . . .	24
2.2.4	<i>Coefficiente de correlação de Pearson</i> . . . . .	25
2.2.5	<i>Teoria Moderna de Portfólio de Markowitz</i> . . . . .	25
2.2.6	<i>Fronteira eficiente</i> . . . . .	27
2.2.7	<i>Diversificação</i> . . . . .	28
2.2.8	<i>Índice Sharpe</i> . . . . .	28
2.3	Computação Evolucionária . . . . .	28
2.3.1	<i>Estimation Distribution Algorithms</i> . . . . .	29
2.3.2	<i>Compact Genetic Algorithms</i> . . . . .	30
2.3.3	<i>Detalhes da implementação do CGA</i> . . . . .	30
3	REFERENCIAL BIBLIOGRÁFICO . . . . .	33
4	METODOLOGIA . . . . .	36
4.1	Classificação da pesquisa . . . . .	36
4.2	Materiais . . . . .	37
4.3	Projeto e desenvolvimento . . . . .	37
4.3.1	<i>Coleta de dados</i> . . . . .	39
4.3.2	<i>Construção das carteiras de criptomoedas</i> . . . . .	39
4.3.3	<i>Implementação do CGA</i> . . . . .	40
4.4	Métricas de avaliação . . . . .	42

5	RESULTADOS E DISCUSSÕES . . . . .	44
5.1	Protocolo experimental . . . . .	44
5.2	Descrição do conjunto de dados . . . . .	45
5.3	Análise exploratória dos dados . . . . .	45
5.4	Resultados da otimização . . . . .	48
5.4.1	<i>Otimização utilizando o CGA</i> . . . . .	48
5.4.2	<i>Avaliação das carteiras</i> . . . . .	52
6	CONCLUSÃO . . . . .	55
	REFERÊNCIAS . . . . .	57

## 1 INTRODUÇÃO

A diversificação de investimentos é uma prática reconhecida e recomendada no mundo das finanças. Como o ditado popular sugere, “não coloque todos os ovos na mesma cesta”, essa analogia simples ilustra o princípio fundamental da diversificação: a distribuição dos recursos de investimento deve ser feita com várias opções para reduzir os riscos associados a um único investimento. Essa estratégia tem sido objeto de estudos de diversas literaturas (MARQUES, 2007).

A seleção de carteiras de investimentos é uma atividade complexa que envolve escolher os ativos que irão compor um portfólio, visando maximizar o retorno e minimizar o risco (MARKOWITZ, 1952). No contexto das criptomoedas, essa tarefa torna-se ainda mais desafiadora devido à alta volatilidade desse mercado.

Conforme definido por Härdle, Harvey e Reule (2020), uma criptomoeda é um ativo digital projetado para ser utilizado como meio de troca, onde a criptografia desempenha um papel fundamental na garantia das transações, controle da criação de novas unidades de valor e verificação das transferências de ativos. Os autores destacam que essas características distintivas das criptomoedas proporcionam uma maior segurança e confiança nas transações realizadas em um ambiente digital. Por outro lado, as criptomoedas não são regulamentadas por governos ou instituições financeiras, estando sujeitas a flutuações em seus valores (TREDINNICK, 2019).

Apesar dessas características, as criptomoedas têm experimentado um aumento significativo em popularidade nos últimos anos, emergindo como uma escolha de investimento cada vez mais adotada por investidores de diversos perfis. Isso é evidenciado por uma pesquisa realizada pela Eurex, uma das principais empresas no mercado de derivativos da Europa, que consultou investidores institucionais tradicionais sobre suas perspectivas em relação às criptomoedas. Os resultados da pesquisa, apresentados na Figura 1, revelam que a maioria dos participantes (51%) já estão ativamente envolvidos em negociações ou investimentos em criptomoedas, enquanto 23% manifestaram abertura para considerar futuros investimentos neste mercado (EUREX, 2021).


Selecionar carteiras de criptomoedas é um desafio significativo para investidores e gestores de portfólio, dado que, além da volatilidade do mercado, há também as múltiplas opções de investimento disponíveis, cada qual com características e níveis de risco únicos. Nesse contexto, o uso de técnicas computacionais pode auxiliar na otimização de carteiras de criptomoedas.

O propósito deste trabalho é apresentar uma implementação do Algoritmo Genético Compacto, também conhecido, do inglês, como *Compact Genetic Algorithm* (CGA) para otimizar carteiras de criptomoedas. A construção das carteiras baseou-se na Teoria Moderna de Portfólio de Markowitz, que estabelece uma base teórica para essa abordagem. O CGA é o responsável por determinar a alocação ideal dos recursos entre as diferentes criptomoedas disponíveis, buscando maximizar o retorno e minimizar o risco do



portfólio de investimentos.

Figura 1 – Resultados da Pesquisa Eurex



Fonte: Adaptado de Eurex (2021)

## 1.1 Objetivos

Nesta seção, são apresentados os objetivos deste trabalho, incluindo o objetivo geral e os objetivos específicos. Além disso, também são descritos os resultados esperados da pesquisa.

### 1.1.1 *Objetivo Geral*

Desenvolver uma metodologia para otimizar o processo de montagem de uma carteira de investimento composta de criptomoedas por meio do uso do CGA, visando maximizar o retorno do investimento e minimizar o risco.

### 1.1.2 *Objetivos Específicos*

Os objetivos específicos deste trabalho são:

- Desenvolver uma aplicação capaz de coletar e armazenar dados de mercado para as criptomoedas selecionadas;
- Aplicar a teoria de Markowitz na construção das carteiras de criptomoedas;
- Implementar o CGA para otimização de propostas de carteiras de criptomoedas otimizadas;
- Avaliar as carteiras geradas pelo CGA.

### 1.1.3 Resultados Esperados

Este trabalho visa proporcionar contribuições para o campo da otimização de carteiras de criptomoedas, especialmente por meio da utilização do CGA. Espera-se que o algoritmo seja capaz de permitir a construção de carteiras otimizadas.

Além disso, espera-se que os resultados possam contribuir para uma melhor compreensão da relação entre os ativos de criptomoedas e como eles podem ser combinados de forma eficiente para a construção de carteiras diversificadas e com menor risco.

Por fim, o trabalho pode servir como uma referência para futuros estudos sobre o tema, incentivando a continuidade da pesquisa e aprimoramento das técnicas de otimização em carteiras.

## 1.2 Justificativa

A crescente disseminação e interesse em criptomoedas nos últimos anos trouxe uma nova dimensão ao cenário de investimentos. No entanto, investir neste mercado é desafiador devido à sua alta volatilidade, falta de regulamentação e complexidade inerente. A seleção criteriosa dos ativos que compõem uma carteira de investimento e a alocação ideal dos recursos são fundamentais para otimizar o retorno e mitigar riscos em um portfólio. Contudo, essa tarefa torna-se ainda mais problemática quando aplicada ao universo das criptomoedas (BERNARDO, 2022).

Nesse cenário, técnicas de otimização desempenham um papel crucial na orientação de investidores e gestores de portfólio na tomada de decisões. O CGA, por sua vez, pode ser uma ferramenta promissora nesse contexto, devido à sua capacidade de encontrar soluções ótimas em problemas complexos.

Além disso, a pesquisa sobre o uso de Algoritmos de Estimação de Distribuição, também conhecido, do inglês, como *Estimation Distribution Algorithms* (EDAs), na seleção de carteiras de investimento pode ser inovadora, especialmente no contexto das criptomoedas.

## 1.3 Estrutura do Trabalho

Este trabalho está estruturado em seis capítulos. Após esta introdução, no Capítulo 2, é descrita uma visão geral dos conceitos práticos e teóricos relevantes para uma compreensão mais profunda deste estudo. No Capítulo 3 é apresentado uma revisão da literatura.

Em seguida, no Capítulo 4 são abordadas as técnicas empregadas neste trabalho, incluindo os métodos escolhidos para sua execução.

No Capítulo 5 é feita uma apresentação dos resultados obtidos e discussões decorrentes desses resultados.

Por fim, no Capítulo 6, são apresentadas as conclusões derivadas deste trabalho, juntamente às sugestões para pesquisas futuras.

## 2 FUNDAMENTAÇÃO TEÓRICA

Neste capítulo são apresentados os principais conceitos e teorias que fundamentam este trabalho. Vale ressaltar que, embora o estudo esteja relacionado à otimização de carteiras de criptomoedas, não é objetivo desta pesquisa discutir, em profundidade, as particularidades e aspectos técnicos das criptomoedas em si. O foco está na apresentação dos conceitos fundamentais de finanças e estatística, além das técnicas computacionais utilizadas para a construção da solução proposta.

Inicialmente, são apresentados alguns aspectos relevantes do mercado das criptomoedas, incluindo as principais características e desafios deste mercado. Em seguida, é abordada a Teoria Moderna de Portfólio de Markowitz, juntamente aos conceitos de finanças e de estatística. Por último, são discutidos os conceitos necessários para o desenvolvimento do CGA.

### 2.1 O mercado das criptomoedas

Um ativo financeiro é um termo que abrange tudo o que possui valor e é suscetível de negociação nos mercados financeiros. Isso engloba uma variedade de instrumentos, como ações, títulos e fundos de investimento. A singularidade dos ativos financeiros reside na natureza de suas reivindicações contratuais e de propriedade. Diferentemente de ativos físicos, como terrenos e imóveis, os ativos financeiros não têm uma presença física ou forma tangível. Seu valor é dinâmico, refletindo as oscilações na oferta e demanda dos mercados em que estão inseridos (MAGALHÃES, 2022).

As criptomoedas são uma categoria específica de ativo financeiro e serviram como base para a construção do portfólio de investimento explorado neste trabalho. Embora relativamente novas, as criptomoedas têm ganhado destaque rapidamente nos últimos anos, atraindo a atenção de investidores, empresas e governos (SICHEL; CALIXTO, 2018). A criação das criptomoedas, conforme proposto por Nakamoto (2008), teve como objetivo oferecer uma alternativa descentralizada ao sistema financeiro tradicional, utilizando uma tecnologia chamada *blockchain*.

No entanto, é fundamental salientar que esse mercado é conhecido por sua volatilidade. Segundo Yin, Nie e Han (2021), essa volatilidade pode ser influenciada por fatores como oferta e demanda, atratividade dos investidores, anonimato dos usuários e incertezas políticas e econômicas. Além disso, os autores demonstram que até mesmo choques no mercado de petróleo podem influenciar na volatilidade das criptomoedas, o que reflete outras formas de incertezas econômicas mais amplas, às quais esse mercado está sujeito.

### 2.1.1 Blockchain


A *blockchain* é uma tecnologia que se caracteriza por ser um sistema de registro distribuído, descentralizado e ponto a ponto. Trata-se de um mecanismo público e imutável, cuja segurança é feita por meio do uso de criptografia. Essa tecnologia é responsável por registrar transações, que são agrupadas em blocos e, em seguida, encadeadas em uma sequência imutável de blocos. Cada transação é identificada por uma marca temporal (*timestamp*) que mostra a data e hora em que cada transação ocorreu e um código de identificação vinculado à transação anterior por meio de uma assinatura digital (NAKAMOTO, 2008).

De acordo com Mallqui e Fernandes (2019), a rede *blockchain* é formada por uma série de computadores (nós) interconectados, que realizam cálculos matemáticos complexos para verificar a precisão e autenticidade das transações. Após a conclusão desses cálculos, um novo bloco é adicionado à cadeia, tornando-se parte da *blockchain*. Essa estrutura de verificação e consenso garante a integridade e a imutabilidade das transações registradas.

Além disso, como um incentivo à participação e manutenção da rede, a criação de novas moedas é concedida aos proprietários que geram novos blocos, enquanto a quantidade total de criptomoedas no caso do *Bitcoin* (BTC), é limitada em 21 milhões, evitando assim o risco de inflação (COCCO; CONCAS; MARCHESI, 2017).

Um exemplo clássico de *blockchain* é ilustrado na Figura 2. A *blockchain* é estendida por cada bloco adicional e, portanto, representa um registro completo do histórico de transações (TX n). Cada bloco pode ser validado pela rede usando meios criptográficos. Além das transações, cada bloco contém um *timestamp*, o valor de *hash*<sup>1</sup> do bloco anterior (“pai”) e um *nonce*, que é um número aleatório usado para gerar o *hash*, sendo ajustado pelos mineradores durante o processo de mineração até que o *hash* do bloco atenda aos critérios específicos estabelecidos pela rede. Esse conceito garante a integridade de toda a *blockchain* até o primeiro bloco (“*Genesis block*”). Os valores de *hash* são únicos, e fraudes podem ser efetivamente evitadas, já que alterações em um bloco na cadeia imediatamente alterariam o valor de *hash* correspondente. Quando a maioria dos nós na rede concorda, através de um mecanismo de consenso, que tanto as transações dentro de um bloco quanto a integridade do próprio bloco são válidas, então esse bloco pode ser acrescentado à cadeia (NOFER *et al.*, 2017).

<sup>1</sup> Os algoritmos de *hash* mais utilizados na tecnologia *blockchain*, incluem SHA-1, SHA-2 e SHA-256, que garantem a integridade dos dados ao criar valores de *hash* únicos para diferentes entradas (AJAO *et al.*, 2019).



Fonte: Nofer *et al.* (2017)

### 2.1.2 A volatilidade das criptomoedas

Apesar dos avanços tecnológicos e da crescente popularidade das criptomoedas, o mercado ainda enfrenta incertezas e desafios. De acordo com Lazo *et al.* (2021), a volatilidade das criptomoedas tem sido uma questão de preocupação para investidores, tornando a tomada de decisão de investimentos no mercado de criptomoedas mais desafiadora.

Um exemplo dessa volatilidade pode ser observado a partir dos dados da criptomoeda pioneira, o BTC. Ao longo dos anos, o BTC experimentou um crescimento em popularidade e valorização, mas também enfrentou períodos de queda acentuada (ULRICH, 2014).

No gráfico da Figura 3 é ilustrada a variação de preço do BTC em reais de 2016 a 2023. Durante esse período, o preço desta criptomoeda apresentou movimentos significativos, com momentos de rápida valorização e quedas bruscas. Em 2021, por exemplo, o BTC atingiu seu pico de valor, que segundo a plataforma CoinMarketCap (2023) foi de aproximadamente R\$374.529,51, consolidando sua posição como uma das criptomoedas mais valiosas do mercado, porém no ano seguinte a criptomoeda teve uma desvalorização superior a 50%.

Figura 3 – Variação do preço do *Bitcoin* de 2016 a 2023



Fonte: CoinMarketCap (2023)

Com isso, entende-se que a volatilidade do BTC não se restringe apenas a momentos de valorização. Ao longo dos anos, a criptomoeda passou por períodos de

desvalorização expressiva, demonstrando a importância de considerar a volatilidade como um fator crucial na tomada de decisões de investimento.

Nesse contexto, a adoção de técnicas de análise de dados e sistemas de tomada de decisão tem emergido como uma alternativa para enfrentar a incerteza do mercado de criptomoedas. Essas abordagens permitem a identificação mais precisa de oportunidades de investimento, contribuindo para a maximização dos retornos financeiros dos investidores (LAZO *et al.*, 2021).

Dentro desse conjunto de técnicas, a aplicação de algoritmos de otimização, como os EDAs, tem se mostrado como ferramentas úteis no processo de otimização de carteiras (XU *et al.*, 2010). Esses algoritmos têm a capacidade de analisar grandes volumes de dados e identificar padrões, fornecendo informações para auxiliar os investidores na tomada de decisões estratégicas.

## 2.2 Seleção de carteira de investimento

No contexto das finanças, a escolha de ativos para investimento é um desafio enfrentado por investidores. Essa decisão implica na seleção da melhor combinação de ativos, levando em consideração não apenas o potencial de retorno, mas também o nível de risco associado (MARQUES, 2007).

Uma abordagem na seleção de ativos para investimento surgiu com o trabalho pioneiro de Markowitz em 1952, que marcou um ponto seminal no campo das finanças. Markowitz desenvolveu um método para a seleção de ativos de investimento, cujas ideias formam a base do que é conhecido como a Moderna Teoria de Finanças (MANGRAM, 2013).

Zapp (2022) destaca que, apesar da existência de diversas metodologias que vão desde métodos manuais até programas mais sofisticados, a otimização de carteira para obter a melhor alocação de ativos ainda é um problema a ser explorado. Assim, a seleção de carteira mostra-se como um desafio que faz parte do dia a dia de investidores e gestores de portfólio.

No âmbito deste trabalho, a estrutura teórica adotada para a construção das carteiras de investimento é a Teoria Moderna de Portfólio de Markowitz. Subsequentemente, as próximas subseções têm o propósito de fornecer embasamento estatístico e conceitos de finanças, visando aprimorar a compreensão dessa teoria.

### 2.2.1 Retorno

O retorno de um investimento reflete o ganho ou perda obtido a partir de determinado período de tempo em uma determinada aplicação financeira (BREALEY; MYERS; ALLEN, 2013). Para calcular o retorno de um investimento, é necessário

considerar uma série de preços de um ativo ao longo do tempo, representados por:

$$P = \{p_1, p_2, \dots, p_n\}$$

Segundo Brealey, Myers e Allen (2013), a fim de criar uma métrica que possa ser comparada entre diferentes ativos, é comum usar o retorno percentual como medida de retorno. Por exemplo, o retorno percentual<sup>2</sup> no tempo  $t = 2$  em relação ao tempo  $t = 1$  é calculado da seguinte maneira:

$$R_2 = \frac{(p_2 - p_1)}{p_1} \quad (1)$$

Uma medida ainda mais relevante para investidores é o retorno médio, que representa a média dos ganhos (SAMANEZ, 2007). Matematicamente, o retorno médio, denotado por  $\mu$ , é definido como:

$$\mu = \frac{1}{n} \sum_{i=1}^n R_i \quad (2)$$

Nessa fórmula, o retorno médio é calculado como a média dos retornos possíveis do ativo, onde  $n$  é o número de cenários possíveis e  $R_i$  representa o retorno percentual para cada cenário.

### 2.2.2 *Risco*

Risco em investimentos refere-se à incerteza associada aos retornos financeiros. Em outras palavras, é a probabilidade de que o retorno real de um investimento seja diferente do retorno esperado. Esse risco está relacionado à volatilidade, que mede o grau de variação dos retornos em relação à média. Quanto maior a volatilidade, maior o risco (SAMANEZ, 2007).

Segundo Samanez (2007), uma medida comum para avaliar o risco é o desvio-padrão, que quantifica a extensão da variação dos retornos. O cálculo do desvio-padrão é realizado pela seguinte equação:

$$\sigma = \sqrt{\frac{1}{n} \sum_{i=1}^n (R_i - \mu)^2} \quad (3)$$

Na fórmula,  $\sigma$  representa o desvio-padrão que mede a variabilidade,  $n$  é o número de observações,  $R_i$  são os retornos em cenários individuais, e  $\mu$  é a média dos retornos. Neste trabalho, o desvio-padrão é adotado como medida de risco.

<sup>2</sup> No cálculo do retorno percentual (Equação (1)), o período  $t = 1$  não permite a obtenção do retorno, uma vez que não há um valor anterior para comparação. Portanto, o retorno percentual é calculado a partir do período subsequente ( $t = 2$ ).



### 2.2.3 Covariância

Assim como a variância é uma medida estatística pela qual se calcula o desvio padrão, que é uma medida de dispersão, a covariância é uma medida estatística que permite chegar ao coeficiente de correlação. Este coeficiente mede o grau de associação linear entre duas variáveis aleatórias, que, neste trabalho, são representadas pelos retornos de ativos financeiros. A covariância avalia como esses retornos variam juntos ao longo do tempo (GUIMARÃES, 2017).

Segundo Farias (2020), a covariância é calculada a partir da média dos produtos dos desvios das variáveis em relação às suas médias correspondentes. A fórmula matemática para o cálculo da covariância entre dois ativos  $X$  e  $Y$  é a seguinte:

$$\text{Cov}(X, Y) = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y}) \quad (4)$$

Onde:

- $\text{Cov}(X, Y)$ : covariância entre  $X$  e  $Y$ .
- $X_i$  e  $Y_i$ : valores das observações individuais de  $X$  e  $Y$ .
- $\bar{X}$  e  $\bar{Y}$ : médias de  $X$  e  $Y$ , respectivamente.
- $n$ : número de observações.

A covariância, quando positiva, sugere que as variáveis tendem a se mover na mesma direção. Por outro lado, uma covariância negativa indica movimentos opostos entre as variáveis. Quando a covariância se aproxima de zero, isso aponta para uma relação fraca entre as variáveis (FARIAS, 2020).

A matriz de covariância é uma disposição sistemática das covariâncias entre todos os pares de ativos considerados em um portfólio, sendo uma matriz quadrada. No modelo de Markowitz (1952), essa matriz é essencial para calcular o risco do portfólio de investimentos. A matriz de covariância apresenta a seguinte disposição:

$$C = \begin{bmatrix} \text{Cov}(X_1, X_1) & \text{Cov}(X_2, X_1) & \cdots & \text{Cov}(X_n, X_1) \\ \text{Cov}(X_1, X_2) & \text{Cov}(X_2, X_2) & \cdots & \text{Cov}(X_n, X_2) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(X_1, X_n) & \text{Cov}(X_2, X_n) & \cdots & \text{Cov}(X_n, X_n) \end{bmatrix}$$

Nessa matriz,

- Nas diagonais principais, como  $\text{Cov}(X_1, X_1)$ ,  $\text{Cov}(X_2, X_2)$ , até  $\text{Cov}(X_n, X_n)$ , encontram-se as variâncias individuais de cada ativo, que representam o grau de variação de cada ativo por si só.

- Nas demais células, fora das diagonais principais, como  $\text{Cov}(X_i, X_j)$ , onde  $i \neq j$ , estão as covariâncias entre os pares de ativos, revelando como esses ativos variam em relação uns aos outros.

#### 2.2.4 Coeficiente de correlação de Pearson

Segundo Guimarães (2017), o coeficiente de correlação entre duas variáveis aleatórias  $X$  e  $Y$ , é uma medida estatística que resulta da padronização da covariância. Essa padronização torna a correlação independente das unidades de medida das variáveis, permitindo uma avaliação mais precisa da relação linear entre elas. A escala desse coeficiente varia de -1 a 1. O autor indica que o valor desse coeficiente pode ser interpretado da seguinte maneira:

- Correlação de +1: Indica uma correlação positiva perfeita, o que significa que as duas variáveis se movem juntas na mesma direção de maneira linear. Quando uma aumenta, a outra também aumenta na mesma proporção.
- Correlação de -1: Representa uma correlação negativa perfeita, em que as variáveis se movem em direções opostas de maneira linear. Quando uma sobe, a outra desce na mesma proporção.
- Correlação de 0: Sugere que não há correlação linear entre as variáveis, ou seja, elas não se movem de forma previsível uma em relação à outra.

Em termos matemáticos, o coeficiente de correlação de Pearson é calculado como:

$$\rho_{xy} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y} \quad (5)$$

Onde,

- $\rho_{xy}$  é o coeficiente de correlação entre  $X$  e  $Y$ .
- $\text{Cov}(X, Y)$  representa a covariância entre  $X$  e  $Y$ .
- $\sigma_X$  e  $\sigma_Y$  são os desvios padrão de  $X$  e  $Y$ , respectivamente.

#### 2.2.5 Teoria Moderna de Portfólio de Markowitz

O modelo desenvolvido por Markowitz (1952), estabelece uma estratégia de investimento que busca maximizar o retorno esperado para um determinado nível de risco, ou minimizar o risco para um determinado nível de retorno. Conhecido como modelo “média-variância”, esse modelo considera o retorno esperado e a volatilidade dos possíveis retornos como aspectos cruciais na definição do portfólio ideal. Para isso, utiliza medidas

estatísticas, como o valor esperado e a variância, para descrever, respectivamente, o retorno e o risco dos investimentos (MARKOWITZ, 1952).

A tomada de decisão no modelo é determinada a partir da análise da média e da covariância dos retornos entre os diferentes ativos disponíveis no mercado. A média dos retornos é utilizada para avaliar o potencial de ganho de cada ativo, enquanto a covariância entre os retornos dos ativos é empregada para capturar a relação de interdependência ou diversificação entre eles (MARQUES, 2007).

Conforme Markowitz (1952), o cálculo do retorno esperado e do risco associado a uma carteira segue os procedimentos a seguir:

O retorno esperado da carteira, denotado por  $R$ , é calculado através da fórmula:

$$R = \sum_{i=1}^n w_i r_i \quad (6)$$

Onde,

- $n$  é o número de ativos na carteira.
- $r_i$  retorno do ativo  $i$  (obtido através da Equação (2)).
- $w_i$  a proporção investida no ativo  $i$ .

A variância da carteira, que é uma medida de risco, é representada por  $\sigma_p^2$  e é calculada pela seguinte fórmula:

$$\sigma_p^2 = \sum_{i=1}^n \sum_{j=1}^n w_i \cdot w_j \cdot \sigma_{ij} \quad (7)$$

Aqui,

- $n$  é o número de ativos na carteira.
- $w_i$  e  $w_j$  são os pesos dos  $i$ -ésimo e  $j$ -ésimo ativos na carteira.
- $\sigma_{ij}$  é a covariância entre os retornos dos ativos  $i$  e  $j$ .

Ambas as fórmulas estão sujeitas à restrição:

$$\sum_{i=1}^n w_i = 1, \quad 0 \leq w_i \leq 1, \quad \forall i = 1, \dots, N \quad (8)$$

A variância da carteira ( $\sigma_p^2$ ) pode ser representada de forma compacta através da Equação 9:

$$\sigma_p^2 = w^T C w \quad (9)$$


Onde,  $w$  é um vetor coluna que contém os pesos dos ativos na carteira,  $C$  é uma matriz de covariância que descreve as relações de covariância entre os retornos de todos os pares de ativos na carteira. Por fim, o termo  $w^T$  representa a transposta do vetor  $w$ .

### 2.2.6 Fronteira eficiente

Markowitz (1952) postula que um investidor racional tem como objetivo maximizar o retorno e minimizar o risco. Isso significa que, ao alocar um conjunto de ativos, surgem inúmeras possibilidades de composições de carteira, cada uma associada a seu próprio nível de risco e retorno. Portanto, a busca por uma carteira ótima torna-se essencial.

Segundo Marques (2007), normalmente, existem duas abordagens comuns para lidar com esse problema. A primeira é fixar o nível de risco desejado e encontrar a composição de ativos que resulte no maior retorno possível. A segunda abordagem é fixar o nível de retorno desejado e determinar a composição do portfólio que minimize o risco.

Figura 4 – Fronteira Eficiente



Fonte: Adaptado de Marques (2007)

Ao obter a composição do portfólio de menor risco para cada nível de retorno desejado ou a composição do portfólio com o maior retorno para cada nível de risco, é possível traçar uma curva que relaciona o risco e o retorno, conhecida como fronteira eficiente. Essa fronteira eficiente representa todas as combinações ótimas de ativos que oferecem o maior retorno possível para cada nível de risco, ou o menor risco possível para cada nível de retorno desejado (MANGRAM, 2013). A Figura 4 é uma representação do gráfico da fronteira eficiente. O retorno esperado está no eixo  $y$  e o risco no eixo  $x$ . A linha traçada é a fronteira eficiente (a Fronteira de Pareto), onde estão as melhores soluções.

### 2.2.7 Diversificação

Os termos “diversificação” e “efeito de diversificação” referem-se à relação entre as correlações e o risco do portfólio. O modelo desenvolvido por Markowitz (1952) também enfatiza a importância da diversificação, buscando minimizar o risco ao distribuir os investimentos entre diferentes ativos. A ideia é evitar concentrar todos os investimentos em um único ativo, pois a combinação de ativos pode resultar em uma menor variância total do portfólio, oferecendo assim uma potencial redução do risco global (MANGRAM, 2013).

### 2.2.8 Índice Sharpe

O índice Sharpe foi desenvolvido por William F. Sharpe, em 1966, e é uma medida utilizada para avaliar o desempenho de um investimento em relação ao risco associado a ele. Em essência, ele fornece uma maneira de quantificar a relação entre o retorno obtido e o risco assumido em um investimento. O índice Sharpe ajuda os investidores a comparar diferentes carteiras ou investimentos com base em seu retorno ajustado pelo risco (LO, 2002).

A fórmula do índice Sharpe é a seguinte:

$$S = \frac{R_p - R_f}{\sigma_p} \quad (10)$$

Onde,

- $S$  representa o índice Sharpe.
- $R_p$  é o retorno da carteira ou investimento.
- $R_f$  é o retorno de um ativo sem risco, muitas vezes representado pelas taxas de juros de títulos do governo<sup>3</sup>.
- $\sigma_p$  é o risco da carteira ou investimento.

Segundo Lo (2002), o índice Sharpe calcula a média do excesso de retorno (a diferença entre o retorno da carteira e o retorno do ativo livre de risco) em relação à volatilidade da carteira. Quanto maior o valor do índice Sharpe, melhor o desempenho do investimento em relação ao risco.

## 2.3 Computação Evolucionária


De acordo com Pozo *et al.* (2005), a Computação Evolucionária (CE) é uma área da Inteligência Artificial (IA) que tem como objetivo encontrar soluções para problemas

<sup>3</sup> No Brasil, por exemplo, o Tesouro Direto oferece títulos públicos de baixo risco, como o Tesouro Selic, o Tesouro Prefixado e o Tesouro IPCA

complexos de otimização e busca, e que tem como inspiração o processo de evolução natural das espécies.

Essas técnicas envolvem a criação de uma população que é submetida a processos de seleção natural. Nesse contexto, a população consiste em um conjunto de indivíduos que representam possíveis soluções para o problema em questão. Cada indivíduo é análogo a um cromossomo na biologia, contendo uma sequência de alelos que armazenam as características específicas desse indivíduo. Essas características são representadas por genes, que podem ser compostos por um ou mais alelos. Cada alelo é a menor unidade de informação em um cromossomo e é representado por 0 ou 1 (NOGUEIRA, 2017). A Figura 5 mostra a diferença entre cromossomo, alelo e gene.

Figura 5 – Representação de um indivíduo de uma população



Fonte: Nogueira (2017)

Nos algoritmos de CE, as características dos indivíduos mais adaptados são transferidas para as próximas gerações, aprimorando o desempenho da busca e da otimização (POZO *et al.*, 2005). Uma das técnicas encontradas no contexto da CE são os EDAs.

### 2.3.1 *Estimation Distribution Algorithms*

Uma abordagem inovadora na área da CE é o uso de EDAs. De acordo com Da Silva (2008), os EDAs propõem uma técnica que substitui os clássicos operadores de *crossover* e mutação por amostragens baseadas em uma distribuição probabilística, uma característica distinta dos Algoritmos Genéticos (AGs) clássicos. Nos EDAs a população é estimada a partir de um grupo de indivíduos selecionados na população. O autor destaca que a população inicial é gerada aleatoriamente e, a cada geração, um grupo de indivíduos é selecionado para estimar a distribuição. Com base nessa distribuição, novos indivíduos são gerados e substituem a população atual ou parte dela, até que um critério pré-definido seja alcançado.

Os EDAs podem ser classificados com base nos tipos de modelos de distribuição probabilística utilizados, sendo eles discreto e contínuo. Esses modelos são baseados nas redes Bayesianas e Gaussianas que são modelos probabilísticos gráficos. As redes

Bayesianas aplicam-se em modelos probabilísticos discretos e as Gaussianas em modelos contínuos (DA SILVA, 2008).

No presente trabalho é utilizado o CGA, que é um EDA com modelo discreto e sem dependência.

### ***2.3.2 Compact Genetic Algorithms***

O CGA foi proposto por Harik, Lobo e Goldberg (1999) como uma solução para problemas de alta dimensionalidade, nos quais a representação do problema é extensa e o espaço de busca é muito grande.

Nesta pesquisa, os autores demonstram algumas diferenças do CGA em relação ao AG simples. Harik, Lobo e Goldberg (1999, p. 288) definem que “O CGA representa a população como uma distribuição de probabilidade sobre o conjunto de soluções”. Isso significa que em cada geração, o CGA seleciona uma solução da distribuição de probabilidade para criar uma nova população, o que permite uma exploração mais eficiente do espaço de busca. A distribuição de probabilidade é atualizada a cada geração com base na aptidão das soluções selecionadas, de modo que as soluções mais aptas têm uma probabilidade maior de serem selecionadas no futuro. Com isso, o CGA reduz os requisitos de memória em comparação com o AG simples (HARIK; LOBO; GOLDBERG, 1999).

Além disso, a maneira como o CGA manipula essa distribuição permite que ele imite o comportamento de ordem um do AG simples. Ou seja, significa que o CGA consegue realizar uma operação específica ou um conjunto de operações de maneira semelhante à forma como o AG simples o faz (seleção, cruzamento e mutação). Essa capacidade é habilitada pela forma como o CGA manipula a distribuição do material genético. Em suma, o CGA utiliza a distribuição de probabilidade como um guia para a busca de soluções ótimas, sem precisar gerar e armazenar todas as possíveis soluções como ocorre no AG simples (HARIK; LOBO; GOLDBERG, 1999).

### ***2.3.3 Detalhes da implementação do CGA***

A implementação do CGA segue um fluxo específico, o qual pode ser visualizado no Algoritmo 1.

A partir dos conhecimentos fornecidos por Harik, Lobo e Goldberg (1999), o fluxo de execução de um CGA pode ser resumido da seguinte maneira:

- Primeiro, é realizada a etapa de inicialização, na qual o vetor de probabilidade é configurado. Cada posição do vetor de probabilidade representa a probabilidade de um alelo ser igual a 1. Tradicionalmente, o valor inicial de cada posição é definido como 0.5, indicando uma chance igual de ser 0 ou 1;

- Em seguida, na etapa de geração, dois indivíduos são criados com base no vetor de probabilidade. Cada posição do indivíduo é gerada aleatoriamente, tomando como referência a probabilidade correspondente no vetor de probabilidade. Esse processo de geração é repetido para formar uma população inicial;
- Posteriormente, os indivíduos passam pela etapa de torneio, na qual seus valores de aptidão (*fitness*) são avaliados. O indivíduo com melhor aptidão é selecionado como o vencedor, enquanto o outro indivíduo é considerado o perdedor;
- Após o torneio, ocorre a etapa de atualização, na qual o vetor de probabilidade é ajustado na direção do vencedor. Para cada posição no vetor de probabilidade, se o alelo correspondente no vencedor for diferente do alelo correspondente no perdedor, o valor da probabilidade naquela posição é incrementado ou decrementado em uma quantidade igual a  $1/n$ , onde  $n$  é o tamanho da população;
- A verificação de convergência é realizada em seguida. O vetor de probabilidade é verificado para determinar se ele convergiu. Isso é feito analisando cada posição do vetor. Se a probabilidade estiver entre 0 e 1 (exclusivos) para qualquer posição, indica que o vetor de probabilidade ainda não convergiu completamente. Nesse caso, a geração é repetida para gerar uma nova população de indivíduos;
- O processo de geração, torneio, atualização e verificação é repetido até que o vetor de probabilidade tenha convergido completamente, ou seja, quando todos os elementos do vetor atingirem probabilidade 0% ou 100%.



### Algoritmo 1 – Pseudocódigo do CGA

- 
- 1) Inicialização() //Inicia o vetor de probabilidade  
     Para  $i := 1$  até  $j$  faça  $p[i] := 0.5$ ;
  
  - 2) Geração() //Gera dois indivíduos através do vetor de probabilidade  
      $a := \text{gerar}(p)$ ;  
      $b := \text{gerar}(p)$ ;
  
  - 3) Torneio() //Os indivíduos são avaliados e competem segundo um valor de fitness  
      $a\_fitness := \text{avaliar}(a)$ ;  
      $b\_fitness := \text{avaliar}(b)$ ;  
     Se  $a\_fitness$  é melhor do que  $b\_fitness$  Então  
          $vencedor := a$ ;  
          $perdedor := b$ ;  
     Senão  
          $vencedor := b$ ;  
          $perdedor := a$ ;
  
  - 4) Atualização() //Atualiza o vetor de probabilidade na direção do vencedor  
     Para  $i := 1$  até  $j$  faça  
         Se  $vencedor[i] \neq Perdedor[i]$  Então  
             Se  $vencedor[i] = j$  Então  
                  $p[i] := p[i] + 1/n$ ;  
             Senão  
                  $p[i] := p[i] - 1/n$ ;
  
  - 5) Verificação() //Verifica se o vetor convergiu  
     Para  $i=1$  até  $j$  faça  
         Se  $p[i] > 0$  e  $p[i] < 1$  Então  
             Geração();
  
  - 6) Finalização:  $p$  representa a solução final

Parâmetros:

$n$ : Tamanho da população

$j$ : Comprimento do cromossomo em bits

---

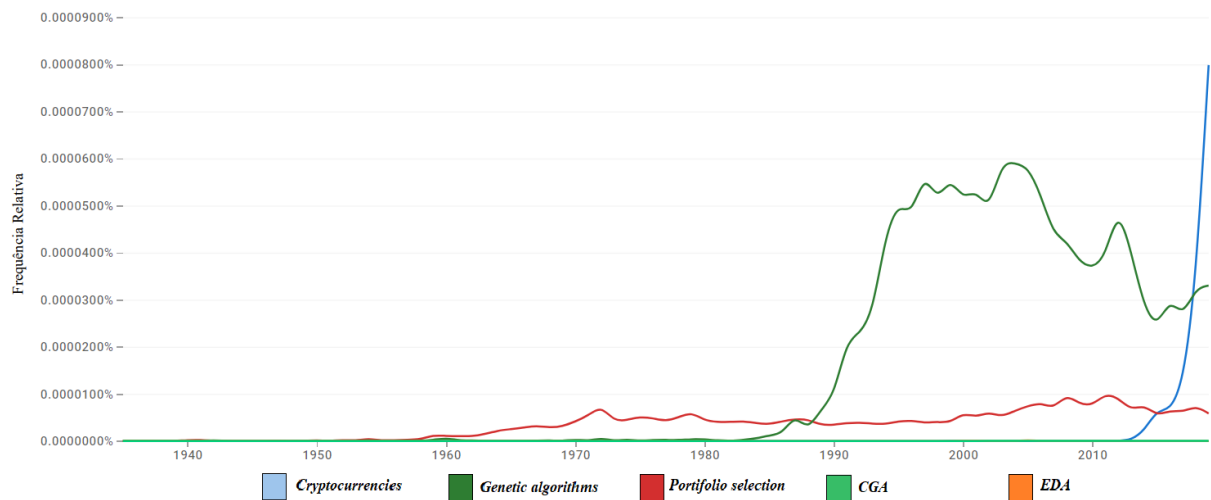
Fonte: Adaptado de Harik, Lobo e Goldberg (1999)

### 3 REFERENCIAL BIBLIOGRÁFICO

Este capítulo apresenta uma breve revisão de estudos relacionados à otimização de portfólio. Embora nem todos os estudos sejam diretamente relacionados ao mercado de criptomoedas, as abordagens e técnicas discutidas forneceram informações para a aplicação desses algoritmos no contexto da otimização de carteiras de criptomoedas. Além disso, foi realizada uma revisão com o objetivo de apresentar o estado da arte no que se refere ao tema.

Através da ferramenta Ngram Viewer, do Google Books (2023) foi possível realizar uma busca do histórico e da frequência de citação das palavras-chave relevantes para este trabalho. Essa ferramenta oferece a possibilidade de analisar o uso e a popularidade de termos específicos ao longo do tempo. No caso deste estudo, a busca foi realizada no período de 1935 a 2019, abrangendo um intervalo de tempo que permitiu capturar tendências e mudanças ao longo das décadas. Vale ressaltar que a pesquisa foi conduzida em inglês, uma vez que essa é uma língua amplamente utilizada em trabalhos acadêmicos. As palavras-chave utilizadas foram: *Cryptocurrencies*, *Portfolio selection*, *Genetic algorithms*, *Estimation Distribution Algorithms* e *Compact Genetic Algorithms*.

Figura 6 – Frequência relativa de citações das palavras chaves deste estudo




Fonte: Adaptado de Google Books (2023)

Com base na Figura 6, a seleção de portfólio destaca-se como um tema de importância para o campo das finanças. Introduzido por Harry Markowitz em um artigo de 1952, intitulado “*Portfolio Selection*”, o conceito manteve uma frequência de citação estável desde a década de 60, com um pico nos primeiros anos de 2010. Isso reflete um interesse constante de pesquisadores e profissionais da área, persistindo até os dias atuais.

Ao analisar o gráfico relacionado à palavra-chave *cryptocurrencies* (criptomoedas), é possível observar um crescimento exponencial ao longo do tempo. Esse aumento na frequência de citação pode indicar um interesse crescente e uma maior relevância das criptomoedas desde a sua criação.

Por meio da Figura 6, observa-se que o AG, uma técnica de otimização proposta por Holland (1975), tem sido estudada e pesquisada em várias áreas, incluindo a otimização de portfólio. A popularidade e relevância dos AGs persistem até os dias atuais.

Figura 7 – Frequência relativa de citações dos algoritmos empregados neste trabalho



Fonte: Adaptado de Google Books (2023)

Por outro lado, ao analisar a Figura 7, é possível observar que o CGA e os EDAs, criados na década de 90, apresentaram uma menor frequência de citação em comparação às outras palavras-chave. Embora essas técnicas tenham sido desenvolvidas há mais de 20 anos, sua aplicação e estudo foram menos explorados. Essa observação sugere uma área de pesquisa com potencial de desenvolvimento e oportunidades para investigações futuras, visando o aprimoramento e a criação de abordagens inovadoras nesse campo.

Nos próximos parágrafos, são apresentadas sínteses dos trabalhos de diferentes autores que forneceram contribuições relevantes para o desenvolvimento desta pesquisa.

O trabalho de Nogueira (2017) apresenta uma versão do CGA capaz de minimizar simultaneamente mais de um objetivo. Essa versão específica do algoritmo é chamada de Algoritmo Genético Compacto com Dominância (AGC-D). O estudo de caso realizado utiliza o AGC-D em combinação com a Regressão Linear Múltipla, para selecionar variáveis que melhorem a predição da concentração de proteína em amostras de trigo, buscando minimizar o erro de predição do modelo e a quantidade de variáveis selecionadas. Essa pesquisa contribui para a otimização do problema de seleção de variáveis, utilizando uma abordagem multiobjetivo e comparando diferentes versões do CGA.

O estudo de Roudier (2007) explora uma abordagem sobre a otimização de carteiras de investimento utilizando AGs. O foco do trabalho é propor uma função objetivo multifatorial que reflita as preferências de investimento específicas do autor e resolver o problema de otimização resultante utilizando um AG. O objetivo é obter carteiras mais robustas, levando em consideração não apenas o retorno esperado e o risco, mas também outros fatores relevantes. Esse trabalho agrega valor ao campo da otimização

de carteiras, abordando as deficiências da teoria de média-variância e oferecendo uma abordagem inovadora com o uso de AGs.

O trabalho de Dias (2008) tem como objetivo principal determinar a fronteira eficiente de investimento por meio da otimização do modelo de média-variância, considerando restrições de cardinalidade e limite inferior de investimento. Dado que esse problema é inteiro e não linear, a obtenção de uma solução exata é desafiadora. Para solucionar isso, o autor introduziu um novo esquema de geração de cromossomos baseado na discretização do espaço. Essa abordagem permitiu a geração de soluções que satisfazem diretamente a restrição de montante total aplicado, proporcionando uma melhoria significativa na eficiência do algoritmo. A contribuição do trabalho de Dias (2008) é relevante para a otimização do modelo de média-variância com restrições, pois oferece uma nova abordagem para a geração de soluções viáveis.

No trabalho de Marques (2007), é abordado um dos problemas fundamentais em finanças: a escolha de ativos para investimento. O autor destaca que, embora Markowitz tenha desenvolvido um método importante para a otimização de carteiras, ele não considerou características cruciais, como a existência de lotes de compra para os ativos e os custos de transação. Nesse contexto, o autor apresenta uma abordagem alternativa para o problema de otimização de carteiras utilizando AGs. Ele utiliza três algoritmos específicos: o algoritmo genético simples, o algoritmo genético multiobjetivo e o algoritmo genético de ordenação não dominante. Essa pesquisa fornece conhecimentos sobre como adaptar e aplicar os algoritmos genéticos na otimização de carteiras de investimento.

O trabalho de Streichert, Ulmer e Zell (2004) investigou o impacto de diferentes operadores de *crossover* em um Algoritmo Evolucionário aplicado ao problema de seleção de carteira com restrições, baseado no modelo de média-variância de Markowitz. Eles introduziram um genótipo de números reais que melhorou o desempenho do algoritmo, independentemente do operador de *crossover* utilizado. Essa pesquisa trouxe uma contribuição ao introduzir a técnica de *hybrid encoding* (codificação híbrida) na otimização de carteiras, que combina elementos da codificação binária e da codificação real para representar soluções no espaço de busca.

## 4 METODOLOGIA

Este capítulo apresenta os métodos e procedimentos adotados para o desenvolvimento da montagem e otimização das carteiras de criptomoedas. Inicialmente, realiza-se uma revisão da classificação da pesquisa, resumindo os aspectos que caracterizam sua natureza, objetivos, abordagem, procedimentos e estilo dentro da área específica de estudo, incluindo a discussão da estrutura básica da *Design Science Research* (DSR).

Na sequência, é discutido o projeto e desenvolvimento, fornecendo uma descrição minuciosa dos materiais e métodos utilizados ao longo da pesquisa, abrangendo o desenvolvimento do processo de coleta, a construção das carteiras e a implementação do CGA.

Finalmente, apresentam-se as métricas de avaliação deste trabalho, fornecendo uma base sólida para a análise e validação dos resultados.

### 4.1 Classificação da pesquisa

Este trabalho é classificado como pesquisa de natureza aplicada, uma vez que se destina a resolver o problema de otimização de carteiras de criptomoedas por meio do CGA. Quanto aos objetivos, a pesquisa é de natureza exploratória, pois visa investigar e compreender as possibilidades e limitações da aplicação do CGA em um contexto prático e atual. Em relação à abordagem, é classificada como uma metodologia quantitativa, fundamentada na análise de dados numéricos relacionados ao desempenho do CGA no problema de otimização proposto.

Em relação ao estilo específico da pesquisa dentro da área de Ciência da Computação, este trabalho se enquadra no estilo “Apresentação de algo diferente”, proposto por Wazlawick (2009). Isso se deve ao fato de que o trabalho apresenta uma técnica para otimização de carteiras de criptomoedas utilizando o CGA, a qual é baseada no modelo de Markowitz.

Quanto ao procedimento metodológico adotado, este trabalho segue a abordagem da DSR, que é uma metodologia de pesquisa voltada para a resolução de problemas contemporâneos relevantes, por meio da criação de artefatos viáveis (LACERDA *et al.*, 2013).

Neste caso, o artefato desenvolvido foi uma instanciação específica do CGA aplicado à otimização de carteiras de criptomoedas. Para orientar o desenvolvimento desta metodologia, foi adotado o *framework* proposto por Peffers *et al.* (2007), o qual é composto pelas etapas descritas na Tabela 1.

Tabela 1 – Etapas do Trabalho

Etapa	Descrição
Identificação do problema	Definição e formalização do problema a ser solucionado. O problema foi descrito ao longo do texto e evidenciado no Capítulo 1.
Definição dos objetivos	Inferir os objetivos a partir da definição do problema e do conhecimento do que é possível e viável. Nas Subseções 1.1.1, 1.1.2 e 1.1.3 são apresentados os objetivos, bem como os resultados esperados.
Projeto e desenvolvimento	Corresponde ao processo de constituição do artefato. Na Seção 4.3 é apresentada a metodologia utilizada para o desenvolvimento da instanciação do CGA.
Demonstração	Envolver a utilização do artefato em experimentação e simulação. No Capítulo 5 são apresentados os resultados deste trabalho, demonstrando o uso do artefato desenvolvido para resolver as instâncias do problema.
Avaliação	Inclui o processo rigoroso de verificação do comportamento do artefato no ambiente para o qual foi projetado. As métricas de avaliação são definidas na Seção 4.4. Posteriormente, as avaliações dos resultados alcançados e a análise dos objetivos obtidos são realizadas nos Capítulos 5 e 6.
Comunicação	O trabalho é apresentado na forma de uma monografia, transmitindo o problema, sua relevância, o artefato desenvolvido, bem como sua utilidade e efetividade.

Fonte: Elaborado pelo autor, 2023

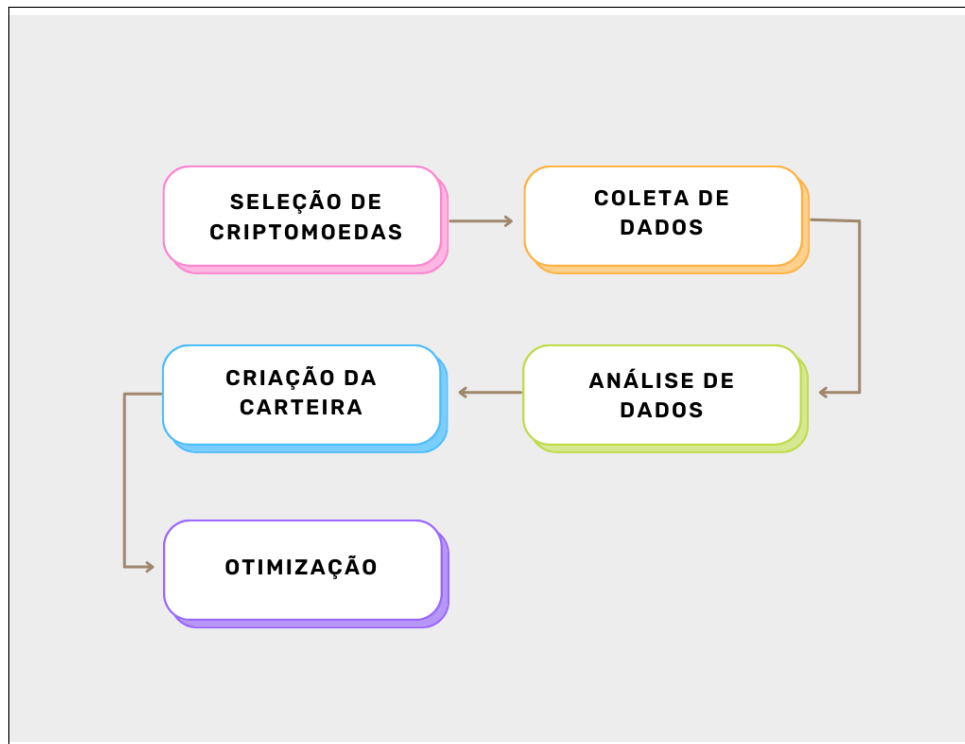
## 4.2 Materiais

Os materiais utilizados para a realização deste trabalho incluem um computador com o sistema operacional Ubuntu 23.10, equipado com um processador Intel® Core™ i7-7500U (quatro núcleos) e 12 GB de RAM. A implementação do CGA e as análises gráficas foram realizadas por meio da linguagem de programação R, utilizando o ambiente de desenvolvimento *RStudio*. Para a coleta de dados foi adotado o ambiente de desenvolvimento *Spyder*, com *Python* 3.10.

## 4.3 Projeto e desenvolvimento

A metodologia de desenvolvimento de *software* adotada para o desenvolvimento do projeto foi a prototipação, caracterizada pela criação de modelos interativos para aprimorar as funcionalidades das implementações (PRESSMAN; MAXIM, 2021). Essa abordagem permitiu uma maior flexibilidade na adaptação às mudanças de requisitos, facilitando a comunicação e o desenvolvimento do trabalho.

Figura 8 – Fluxograma de execução do projeto



Fonte: Elaborado pelo autor, 2023

O escopo do problema envolveu várias etapas essenciais para o desenvolvimento e avaliação das carteiras de criptomoedas. Inicialmente, a seleção das criptomoedas que compõem as carteiras, foi baseada na capitalização de mercado<sup>1</sup>, considerando as 15 maiores criptomoedas em três períodos de tempo distintos, utilizando a plataforma CoinMarketCap (2023) como referência.

Posteriormente, foi realizada a coleta do histórico de preços de fechamento dessas criptomoedas. Esse processo compreendeu a obtenção de dados históricos para dois anos, divididos em dois conjuntos temporais: um conjunto de treino para o primeiro ano e um conjunto de teste para o segundo ano, seguindo uma sequência temporal.

Uma vez obtidos os dados, uma análise foi conduzida para compreender as tendências e o desempenho das criptomoedas ao longo do tempo. Essa análise envolveu a criação de gráficos e tabelas, que forneceram uma visão abrangente do mercado e do comportamento das criptomoedas.

Em seguida, as carteiras de criptomoedas foram criadas, e, por fim, elas foram otimizadas por meio do CGA. A Figura 8 mostra o fluxograma que demonstra essas etapas.

As subseções a seguir detalham as etapas da Figura 8. As implementações correspondentes deste projeto estão hospedados publicamente no repositório do GitHub<sup>2</sup>.

<sup>1</sup> A capitalização de mercado de uma criptomoeda é o preço atual da criptomoeda multiplicado por sua quantidade em circulação

<sup>2</sup> <https://github.com/Carlos-Eduardo99/Portfolio-Optimization>

#### 4.3.1 Coleta de dados

A coleta de dados baseou-se no acesso à API (*Application Programming Interface*) pública da CoinGecko<sup>3</sup>. O código desenvolvido consistiu em uma série de funções, que permitiram obter o histórico de preços de fechamento das criptomoedas selecionadas e salvar esses dados em um arquivo CSV (*Comma-separated values*).

Primeiramente, obteve-se as 15 maiores criptomoedas com base em sua capitalização de mercado no período desejado. A partir dessa consulta, os identificadores de cada uma dessas criptomoedas foram inseridos em um vetor.

Ao conduzir os testes iniciais, observou-se que a API possui um limite de taxa de requisições de, aproximadamente, 30 chamadas por minuto. Portanto, para evitar exceder esse limite e garantir que as solicitações de dados históricos fossem tratadas eficientemente, o vetor de criptomoedas foi dividido em três lotes, cada um contendo 5 criptomoedas. Daí em diante, foram adicionados intervalos de tempo entre as solicitações de cada lote de criptomoedas. Essas medidas garantiram que os preços de fechamento de cada criptomoeda fossem coletados corretamente.

Para obter os dados, foram realizadas requisições específicas a API, indicando a moeda desejada. Além disso, foram incluídos parâmetros na requisição para definir o período de coleta, incluindo:

- A moeda em que os preços de fechamento são expressos. No caso, a moeda escolhida foi o Real Brasileiro (BRL).
- O período de tempo desejado para a coleta de dados.

Como resultado da implementação, foram gerados arquivos CSV nos quais cada linha representou um dia, enquanto cada coluna se referiu a uma criptomoeda específica. Esses arquivos forneceram um histórico completo dos preços de fechamento na data especificada. Posteriormente, esses dados foram utilizados para as análises discutidas no Capítulo 5.

#### 4.3.2 Construção das carteiras de criptomoedas

Antes de prosseguir com a construção das carteiras de criptomoeda, um *script* foi desenvolvido para explorar os dados das criptomoedas selecionadas. Este *script* plota gráficos, permitindo uma visualização das tendências, padrões e comportamentos das criptomoedas ao longo do tempo. Essa etapa proporcionou uma melhor compreensão das características das criptomoedas, possibilitando a identificação de possíveis relações entre elas. A análise incluiu uma plotagem da matriz de correlação, gerada com o coeficiente de correlação de Pearson, para fins de uso no método de Markowitz.

<sup>3</sup> <https://www.coingecko.com/pt/api>



Após a análise exploratória dos dados, foi realizada a etapa de construção das carteiras. Inicialmente, os preços de fechamento de cada ativo foram extraídos do arquivo CSV. Em seguida, procedeu-se com o cálculo do retorno percentual diário conforme a Equação (1) para cada criptomoeda. A partir dos retornos percentuais diários, determinou-se a média dos retornos conforme a Equação (2). Por fim, a matriz de covariância foi obtida a partir dos retornos calculados, conforme a Equação (4).

Por fim, criou-se uma função personalizada para aplicar o método de Markowitz, a qual retorna o risco e o retorno de uma carteira. O retorno da carteira foi calculado conforme a Equação (6), enquanto o risco da carteira foi determinado como indicado na Equação (7). As alocações dos ativos (pesos) são determinados pelo algoritmo CGA, cuja implementação é abordada na próxima subseção.

### 4.3.3 Implementação do CGA

O CGA foi implementado seguindo o modelo proposto por Harik, Lobo e Goldberg (1999), cujo fluxograma de execução pode ser visualizado na Figura 9.

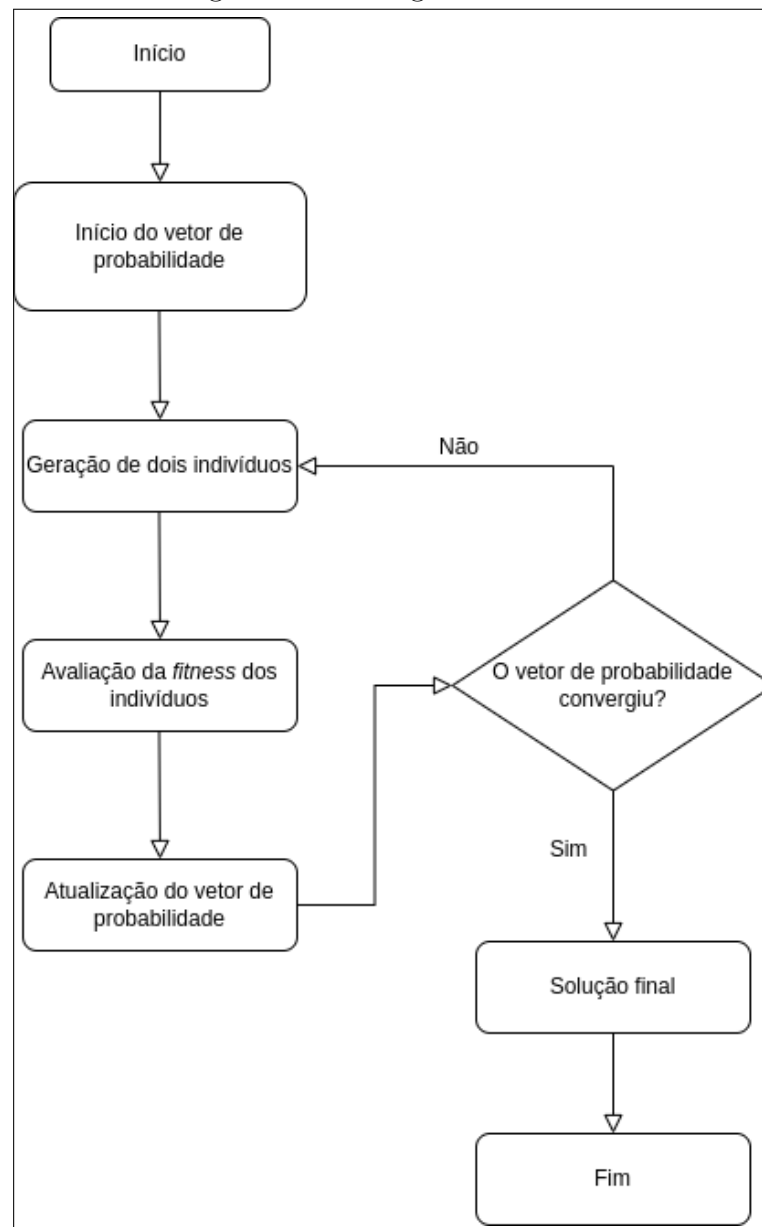
Neste formato, o CGA faz uso de uma função especializada que tem como finalidade calcular o retorno e o risco de cada carteira gerada pelo algoritmo. Esta função desempenha um papel crucial, pois é através dela que se obtém o valor da aptidão (*fitness*) de um indivíduo, ou seja, a qualidade de uma configuração específica da carteira.

Para avaliar o desempenho das carteiras geradas, a função de *fitness* utiliza como base o índice Sharpe conforme a Equação (10), quanto maior o índice Sharpe, melhor o desempenho da carteira. Na análise, optou-se por considerar o valor de  $R_f$  (retorno de um ativo sem risco) igual a zero. Isso significa que não há retorno adicional proporcionado por um ativo livre de risco, tornando o desempenho da carteira mais sensível ao retorno total e ao risco associado aos ativos incluídos. Embora na prática o retorno de um ativo sem risco não seja necessariamente zero, essa escolha simplificada é comum em análises financeiras para fins de comparação e interpretação (SCHMIDT, 2023).

No contexto do algoritmo, um indivíduo (cromossomo) foi representado por um vetor de 15 posições, correspondentes às 15 criptomoedas disponíveis. Esse vetor binário utiliza “1” para indicar a inclusão de um ativo na carteira e “0” para sua ausência. Para converter esse vetor binário em alocações ponderadas de ativos, foi desenvolvida uma função que distribui os pesos igualmente entre os ativos com valor “1”, garantindo que a soma dos pesos seja sempre igual a 1, conforme estabelecido na restrição (8) imposta pelo modelo de Markowitz .

A função de geração de um indivíduo no algoritmo apresenta uma peculiaridade. Além de determinar quais ativos serão incluídos ou excluídos na carteira, ela também implementa uma restrição de cardinalidade. Essa restrição estipula a quantidade mínima de ativos que a carteira deve conter. Assim, a restrição de cardinalidade garante que

Figura 9 – Fluxograma do CGA



Fonte: Elaborado pelo autor, 2023

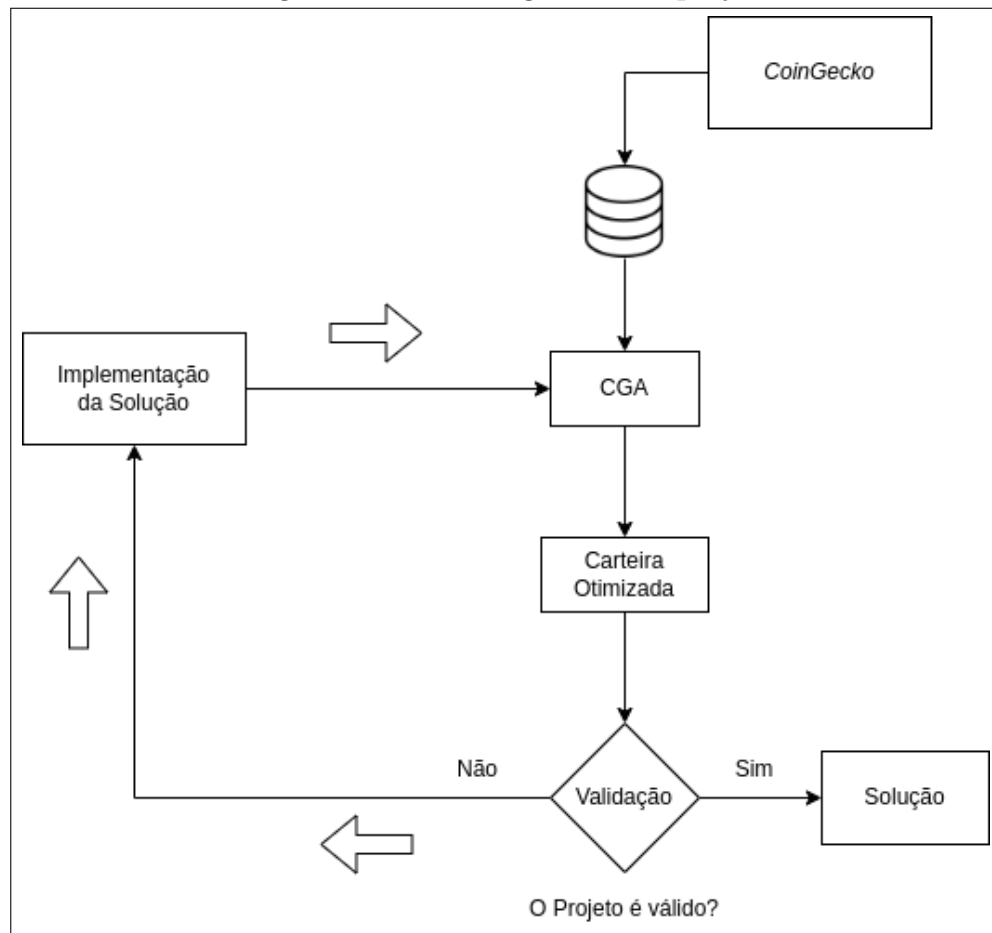
a carteira sempre terá um número mínimo de ativos, proporcionando diversificação e equilíbrio em todas as configurações geradas.

No funcionamento do algoritmo, a busca pela alocação ótima de ativos foi realizada de maneira iterativa e repetida. Em cada execução, uma nova carteira otimizada foi obtida. Para construir a fronteira eficiente, o algoritmo foi executado repetidamente, gerando assim 1000 carteiras otimizadas em diferentes configurações. Essas carteiras formaram a base para a análise da eficiência na alocação de ativos. Na análise da fronteira eficiente, as carteiras resultantes de cada execução foram plotadas e a carteira com o maior índice Sharpe, que reflete o melhor equilíbrio entre retorno e risco, foi destacada no gráfico como a solução ótima. Esse procedimento permitiu identificar as alocações de ativos que maximizaram o retorno em relação ao risco e, portanto, determinando a carteira ideal.

#### 4.4 Métricas de avaliação

Para medir o desempenho do CGA e determinar se ele é capaz de gerar carteiras otimizadas de forma consistente, foram realizados experimentos em momentos de mercado com diferentes características, incluindo períodos de alta, baixa e estabilidade.

Figura 10 – Ciclo regulador do projeto



Fonte: Elaborado pelo autor, 2023

O processo de avaliação conta com duas etapas importantes:

1. Geração de carteiras no conjunto de treino: No período de treino, foram geradas 1000 carteiras otimizadas pelo CGA. Dentre essas carteiras, a melhor foi selecionada com base no índice Sharpe. Importante notar que o algoritmo realiza uma “operação cega”, pois não possui conhecimento prévio dos dados do conjunto de teste.
2. Conjunto de dados de teste: Na etapa de teste, alguns dos procedimentos de construção de carteiras foram repetidos. Isso engloba a realização do cálculo do retorno percentual e retorno médio, porém em um período temporal distinto. No entanto, ao calcular o retorno da carteira, são empregados os pesos previamente obtidos a partir das 1000 carteiras geradas no conjunto de treino.

A métrica de avaliação adotada é determinar se a melhor carteira apontada pelo CGA no conjunto de treino, com base no índice Sharpe, está entre os 100 melhores retornos no conjunto de teste. Essa abordagem proporciona uma medida sólida da capacidade do algoritmo de otimização em diferentes contextos de mercado. A Figura 10, mostra esse ciclo de avaliação.

Essa abordagem iterativa de avaliação e ajuste permitiu aperfeiçoar continuamente a implementação do CGA. Os resultados obtidos foram utilizados como base para tomar decisões e promover melhorias na implementação. Os resultados desses experimentos são apresentados no próximo capítulo.

## 5 RESULTADOS E DISCUSSÕES

Este capítulo apresenta os resultados alcançados a partir da análise dos dados coletados e da aplicação do algoritmo CGA na otimização de carteiras de criptomoedas. O capítulo está organizado em quatro seções principais.

A primeira seção descreve o protocolo experimental utilizado para coleta dos dados, detalhando os procedimentos adotados. A segunda seção foca na apresentação dos dados coletados, oferecendo uma análise abrangente do conjunto de dados.

A terceira seção consiste em uma análise exploratória, utilizando gráficos e tabelas para examinar as principais características e padrões presentes nos dados. Essa análise permitiu obter informações sobre o comportamento das criptomoedas e identificar possíveis relações entre elas.

Por fim, na quarta seção, são apresentados os resultados obtidos por meio da aplicação do CGA. São discutidas as carteiras ótimas encontradas, seus pesos correspondentes e os indicadores de desempenho associados. Além disso, é apresentada a avaliação das carteiras geradas pelo CGA com base no conjunto de teste.

### 5.1 Protocolo experimental

O protocolo experimental consiste em três experimentos realizados com base em conjuntos de dados capturados em momentos temporais diferentes. O primeiro experimento utilizou os dados do período que foi de 01/01/2020 a 02/01/2022 (2 anos). Durante este período, o conjunto de treino abrangeu de 01/01/2020 a 01/01/2021 (1 ano), enquanto o conjunto de teste correspondeu ao período de 02/01/2021 a 02/01/2022 (1 ano). O segundo experimento compreendeu o período de 01/06/2020 a 02/06/2022. O conjunto de treino para este experimento incluiu o período de 01/06/2020 a 01/06/2021, e o conjunto de teste cobriu o intervalo de 02/06/2021 a 02/06/2022. O terceiro experimento foi de 01/01/2021 a 02/01/2023. Durante este experimento, o conjunto de treino abrangeu de 01/01/2021 a 01/01/2022, enquanto o conjunto de teste englobou o período de 02/01/2022 a 02/01/2023. A Tabela 2 mostra com mais detalhes essa divisão.

Tabela 2 – Divisão dos conjuntos de dados

Experimento	Período de Treino	Período de Teste
1	01-01-2020 a 01-01-2021	02-01-2021 a 02-01-2022
2	01-06-2020 a 01-06-2021	02-06-2021 a 02-06-2022
3	01-01-2021 a 01-01-2022	02-01-2022 a 02-01-2023

Fonte: Elaborado pelo autor, 2023

## 5.2 Descrição do conjunto de dados

Na Tabela 3, é possível visualizar as 15 criptomoedas selecionadas para a realização de cada experimento, representadas pelo seu nome e símbolo.

Tabela 3 – Criptomoedas selecionadas para os experimentos

Posição	Experimento 1	Experimento 2	Experimento 3
1	Bitcoin (BTC)	Bitcoin (BTC)	Bitcoin (BTC)
2	Ethereum (ETH)	Ethereum (ETH)	Ethereum (ETH)
3	Ripple (XRP)	Ripple (XRP)	Tether (USDT)
4	Tether (USDT)	Tether (USDT)	Ripple (XRP)
5	Bitcoin Cash (BCH)	Bitcoin Cash (BCH)	Litecoin (LTC)
6	Litecoin (LTC)	Bitcoin SV (BSV)	Bitcoin Cash (BCH)
7	EOS (EOS)	Litecoin (LTC)	Binance Coin (BNB)
8	Binance Coin (BNB)	Binance Coin (BNB)	Chainlink (LINK)
9	Bitcoin SV (BSV)	EOS (EOS)	Cardano (ADA)
10	Monero (XMR)	Tezos (XTZ)	Polkadot (DOT)
11	Stellar (XLM)	Cardano (ADA)	USD Coin (USDC)
12	Tron (TRX)	Cronos (CRO)	Stellar (XLM)
13	Cardano (ADA)	Chainlink (LINK)	Bitcoin SV (BSV)
14	Tezos (XTZ)	Stellar (XLM)	Wrapped Bitcoin (WBTC)
15	LEO Token (LEO)	LEO Token (LEO)	Monero (XMR)

Fonte: Elaborado pelo autor, 2023

A Tabela 4 mostra uma parcela do conjunto de dados de treino, onde é possível visualizar o preço de fechamento, em reais, de cada uma das 15 criptomoedas no Experimento 1. A primeira coluna representa a data do preço de fechamento de cada ativo, enquanto as outras colunas representam o preço de fechamento de cada criptomoeda.

Tabela 4 – Preço de Fechamento: Conjunto de treino do Experimento 1

Data	BTC	ETH	XRP	USDT	BCH	LTC	EOS	...
01-01-2020	28924.29	519.32	0.77	4.01	822.33	166.14	10.39	...
02-01-2020	28916.72	524.51	0.77	4.01	821.41	167.24	10.45	...
03-01-2020	28028.81	511.34	0.75	4.02	787.57	158.63	9.88	...
04-01-2020	29689.05	543.74	0.78	4.06	901.29	170.77	10.70	...
...	...	...	...	...	...	...	...	...
01-01-2021	150730.83	3836.08	1.14	5.19	1784.10	648.15	13.48	...


Fonte: Elaborado pelo autor, 2023

## 5.3 Análise exploratória dos dados

Nas Figuras 11, 12 e 13, são apresentados gráficos que demonstram a variação dos preços de fechamento das criptomoedas no período do Experimento 1. O eixo horizontal representa as datas, enquanto o eixo vertical representa os preços de fechamento em reais. Considerando a significativa disparidade nos preços de fechamento das criptomoedas, realizou-se o agrupamento daquelas que demonstraram maior proximidade nos preços em


cada gráfico. Essa abordagem foi adotada com o intuito de simplificar a visualização e análise dos dados.

Figura 11 – Histórico do preço de fechamento do *Bitcoin*




Fonte: Elaborado pelo autor, 2023

Figura 12 – Histórico do preço de fechamento 1



Fonte: Elaborado pelo autor, 2023

Figura 13 – Histórico do preço de fechamento 2



Fonte: Elaborado pelo autor, 2023

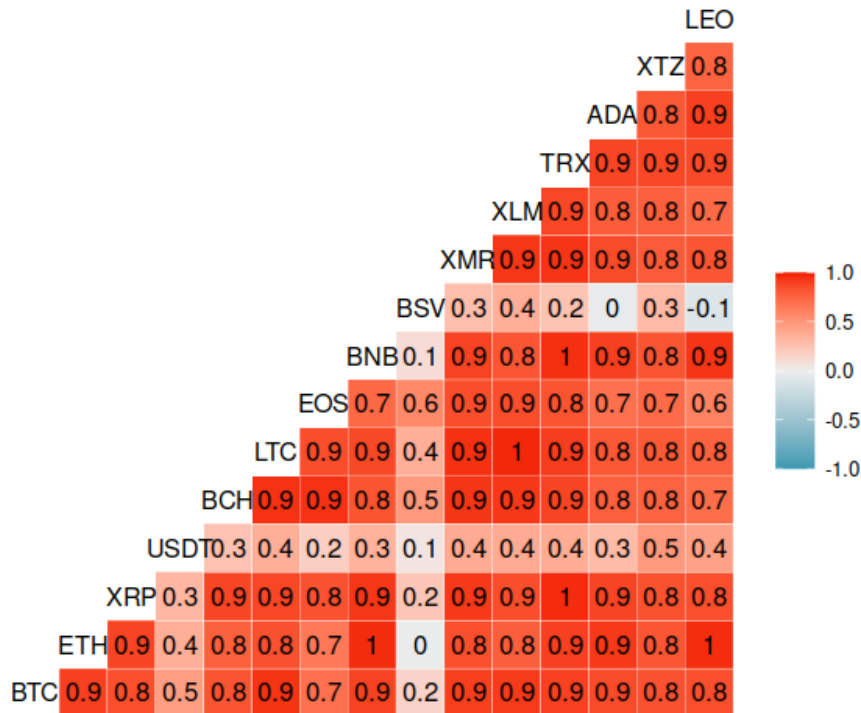
Ao analisar os gráficos, é possível identificar uma tendência no mercado como um todo. A partir do início do ano de 2020, observa-se um crescimento expressivo no valor dessas criptomoedas. No entanto, na metade do ano de 2021, houve um período de queda, seguido de uma recuperação em alguns meses posteriores. Essa tendência pode sugerir que o mercado de criptomoedas esteve sujeito a flutuações e que o comportamento dos ativos é sensível a eventos ou fatores específicos que ocorreram durante esse período.

Para quantificar a correlação entre esses ativos, na Figura 14, pode-se visualizar os coeficientes de correlação. Nessa matriz, observa-se uma predominância dos coeficientes próximos a 1, sendo que apenas os ativos BSV e USDT apresentam coeficientes de correlação próximos a 0. Isso dá evidência da alta correlação existente entre os ativos selecionados. No entanto, essa alta correlação não é necessariamente um indicativo positivo para as carteiras de criptomoedas, pois sugere que esses ativos tendem a se mover juntos na mesma direção, de maneira linear.

Isso vai contra os princípios da diversificação, que geralmente buscam reduzir o risco, distribuindo investimentos em ativos com correlação negativa ou movimentos independentes (próximo a zero). Em suma, a alta correlação entre as criptomoedas significa que, em momentos de volatilidade, todas as moedas podem ser afetadas negativamente, o que pode aumentar o risco da carteira.



Figura 14 – Matriz de correção do Experimento 1



Fonte: Elaborado pelo autor, 2023

## 5.4 Resultados da otimização

Nesta seção, são apresentados os resultados obtidos por meio da otimização utilizando o CGA. Inicialmente, são mostrados os dados obtidos a partir da aplicação do modelo de Markowitz. Em seguida, são exibidas as melhores carteiras otimizadas em cada um dos três experimentos, destacando os pesos atribuídos a cada criptomoeda na composição ideal da carteira. Por fim, é apresentada a fronteira eficiente e a análise a partir do conjunto de teste, proporcionando uma visão abrangente do desempenho das carteiras otimizadas.

### 5.4.1 Otimização utilizando o CGA

Inicialmente, através da aplicação do modelo de Markowitz, obteve-se os retornos médios percentuais para o conjunto de treino dos três experimentos. A Tabela 5 apresenta esses valores, os quais constituem uma variável importante no cálculo do retorno esperado das carteiras otimizadas.


A Figura 15 exibe o retorno médio percentual e o desvio-padrão de cada criptomoeda no conjunto de treino do Experimento 1. Pode-se perceber que as criptomoedas BSV, XLM e XTZ possuem o maior desvio-padrão, enquanto o USDT e LEO apresentam os menores. É importante observar que, apesar da alta variância, essas criptomoedas também exibem um retorno médio percentual mais elevado.

Tabela 5 – Retornos médios percentuais

Experimento 1		Experimento 2		Experimento 3	
Símb.	Média	Símb.	Média	Símb.	Média
BTC	0.0053	BTC	-0.0001	BTC	0.0023
ETH	0.0068	ETH	-0.0002	ETH	0.0061
XRP	0.0029	XRP	-0.0015	USDT	0.0002
USDT	0.0008	USDT	-0.0001	XRP	0.0068
BCH	0.0038	BCH	-0.0028	LTC	0.0025
LTC	0.0052	BSV	-0.0025	BCH	0.0031
EOS	0.0021	LTC	-0.0019	BNB	0.0101
BNB	0.0047	BNB	0.0002	LINK	0.0043
BSV	0.0057	EOS	-0.0032	ADA	0.0078
XMR	0.0053	XTZ	0.0002	DOT	0.0059
XLM	0.0054	ADA	-0.0020	USDC	0.0002
TRX	0.0041	CRO	0.0025	XLM	0.0046
ADA	0.0070	LINK	-0.0026	BSV	0.0018
XTZ	0.0037	XLM	-0.0021	WBTC	0.0023
LEO	0.0023	LEO	0.0025	XMR	0.0031

Fonte: Elaborado pelo autor, 2023

Figura 15 – Retorno médio e Desvio-padrão

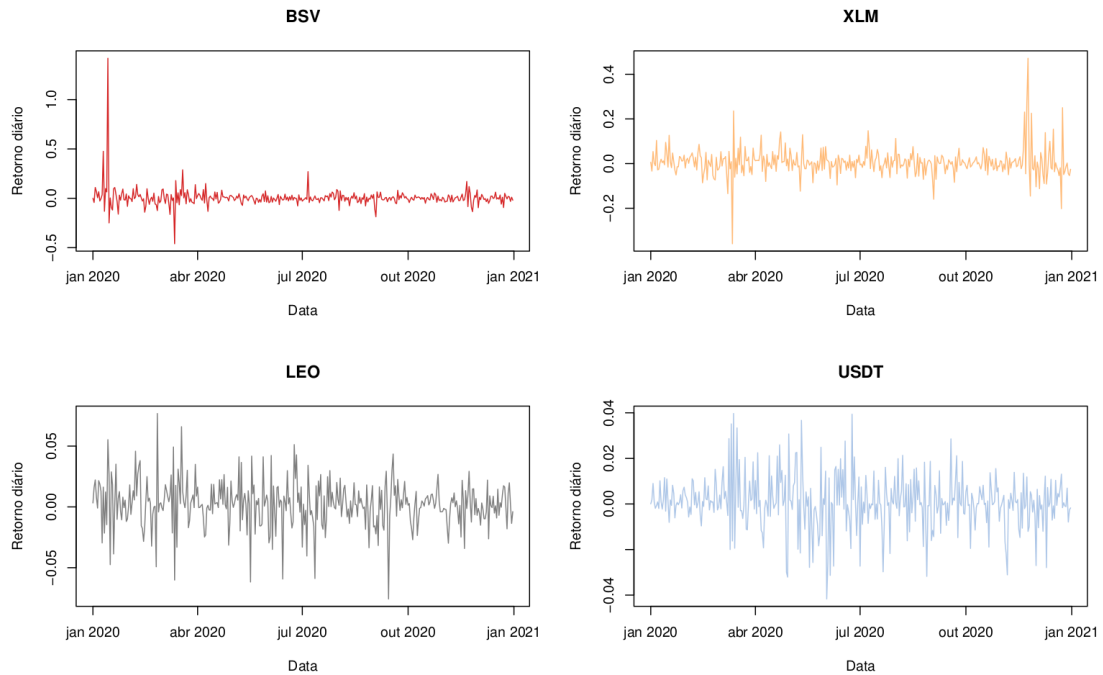


Fonte: Elaborado pelo autor, 2023

Na Figura 16, é mostrado o retorno percentual diário das duas criptomoedas com o maior desvio-padrão, BSV e XLM, juntamente com as duas criptomoedas com o menor desvio-padrão, USDT e LEO. Esse gráfico permite visualizar as flutuações diárias nos

preços dessas criptomoedas e compreender a volatilidade associada a cada ativo. Observa-se que as criptomoedas com maior desvio-padrão exibem oscilações mais acentuadas, o que é reflexo da maior variabilidade de seus retornos diários em comparação às criptomoedas com menor desvio-padrão.

Figura 16 – Retorno percentual diário do BSV, XLM, LEO e USDT



Fonte: Elaborado pelo autor, 2023

Para a aplicação do CGA na otimização das carteiras de criptomoedas, foram definidos parâmetros específicos. O número máximo de gerações foi estabelecido em 3000, com uma população de 100 indivíduos. Além disso, uma restrição de cardinalidade igual a 2 foi imposta, limitando o número mínimo de ativos em cada carteira. O algoritmo foi executado 1000 vezes gerando assim 1000 carteiras otimizadas com diferentes valores de índice Sharpe.

Na Tabela 6, são apresentados os valores de retorno, risco e o índice Sharpe da melhor carteira otimizada, nos três experimentos. A melhor carteira do Experimento 2 destacou-se ao exibir o maior retorno esperado, superando as carteiras dos demais experimentos, além de registrar o maior índice Sharpe.

Tabela 6 – Resultados da otimização

<b>Carteiras</b>	<b>Retorno</b>	<b>Risco</b>	<b>Índice Sharpe</b>
Experimento 1	0.45%	4.46%	0.101
Experimento 2	0.65%	5.54%	0.116
Experimento 3	0.50%	5.76%	0.087

Fonte: Elaborado pelo autor, 2023

A Tabela 7 apresenta a distribuição dos pesos das melhores carteiras, determinadas com base no índice Sharpe, nos três experimentos realizados. É perceptível que os

pesos são idênticos em todos os experimentos. Essa uniformidade é uma consequência da limitação do CGA em operar apenas com representações binárias.

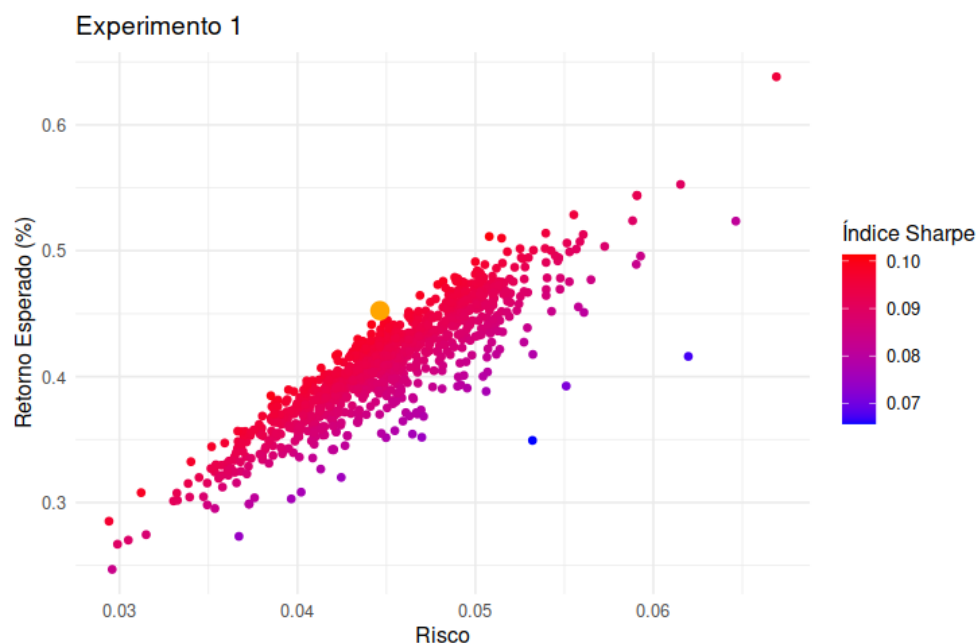
Tabela 7 – Distribuição dos pesos nas carteiras ótimas

Experimento 1		Experimento 2		Experimento 3	
Símb.	Peso	Símb.	Peso	Símb.	Peso
BTC	0%	BTC	0%	BTC	0%
ETH	0%	ETH	0%	ETH	16.67%
XRP	0%	XRP	0%	USDT	0%
USDT	0%	USDT	0%	XRP	16.67%
BCH	16.67%	BCH	14.29%	LTC	16.67%
LTC	16.67%	BSV	0%	BCH	0%
EOS	0%	LTC	0%	BNB	0%
BNB	16.67%	BNB	14.29%	LINK	16.67%
BSV	16.67%	EOS	14.29%	ADA	0%
XMR	16.67%	XTZ	14.29%	DOT	16.67%
XLM	0%	ADA	14.29%	USDC	0%
TRX	0%	CRO	14.29%	XLM	16.67%
ADA	0%	LINK	0%	BSV	0%
XTZ	0%	XLM	14.29%	WBTC	0%
LEO	16.67%	LEO	0%	XMR	0%

Fonte: Elaborado pelo autor, 2023

A Figura 17 exibe a fronteira eficiente, que representa as 1000 carteiras geradas no conjunto de treino do Experimento 1. Dentre essas carteiras, aquela que apresentou o melhor índice Sharpe foi destacada em laranja. Esta carteira apresenta a combinação ótima de ativos que equilibram ao máximo o retorno em relação ao risco.

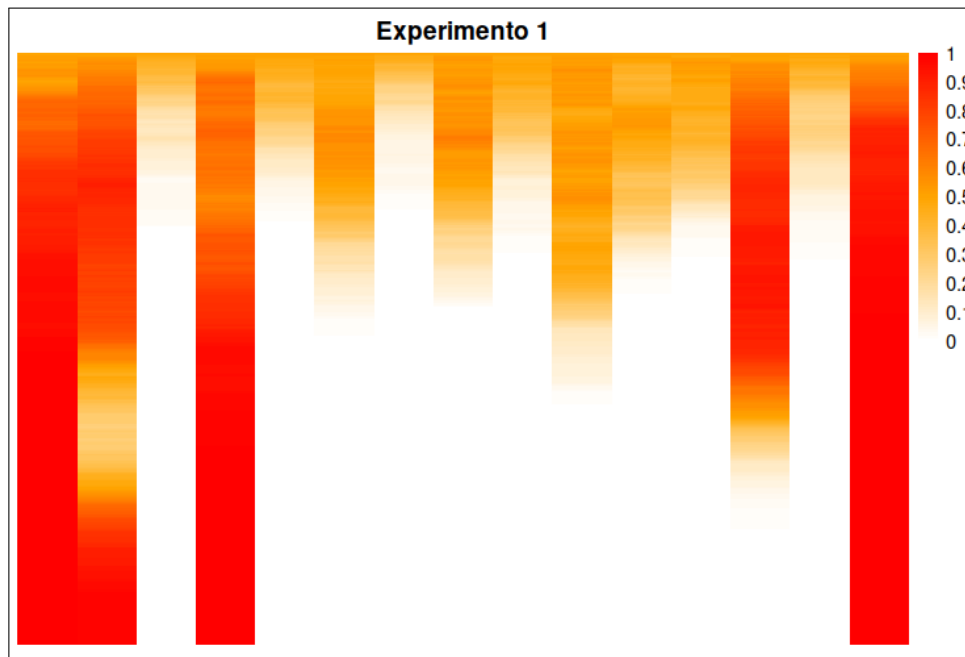
Figura 17 – Fronteira eficiente do Experimento 1



Fonte: Elaborado pelo autor, 2023

Na Figura 18 , é apresentado o mapa de calor do vetor de probabilidade da melhor carteira otimizada do Experimento 1. Observa-se que ao longo das gerações de indivíduos, no processo de otimização, o vetor de probabilidade passa por alterações nas probabilidades de cada posição. As cores mais escuras, representadas em laranja, indicam alta probabilidade daquela posição assumir valor igual a um, enquanto as cores mais claras, próximas a zero e representadas em branco, indicam baixa probabilidade. Esse processo de adaptação ocorre até que a condição de convergência seja alcançada, com valores extremos (zero ou um) em todas as posições do vetor.

Figura 18 – Mapa de calor do vetor de probabilidade do Experimento 1



Fonte: Elaborado pelo autor, 2023

#### 5.4.2 Avaliação das carteiras

Na avaliação das carteiras otimizadas, o procedimento baseou-se no cálculo do retorno médio percentual do conjunto de teste em cada experimento. Em seguida, utilizou-se desses retornos para calcular o desempenho das carteiras, incorporando os pesos previamente obtidos pelo CGA.

No primeiro experimento, a melhor carteira encontrada no conjunto de teste ficou na 22ª posição dentre as 1000 carteiras geradas no conjunto de validação, registrando um retorno de 0.89% do valor investido. No segundo experimento, a melhor carteira ficou em 17ª com um retorno de 0.11%. No terceiro experimento, a carteira ficou em 99ª, mas teve um retorno negativo de -0.14%. A Figura 19 apresenta esses dados na forma de um gráfico de barras, onde a melhor carteira em cada experimento é destacada em vermelho.

Com base nesses resultados, pode-se inferir que:

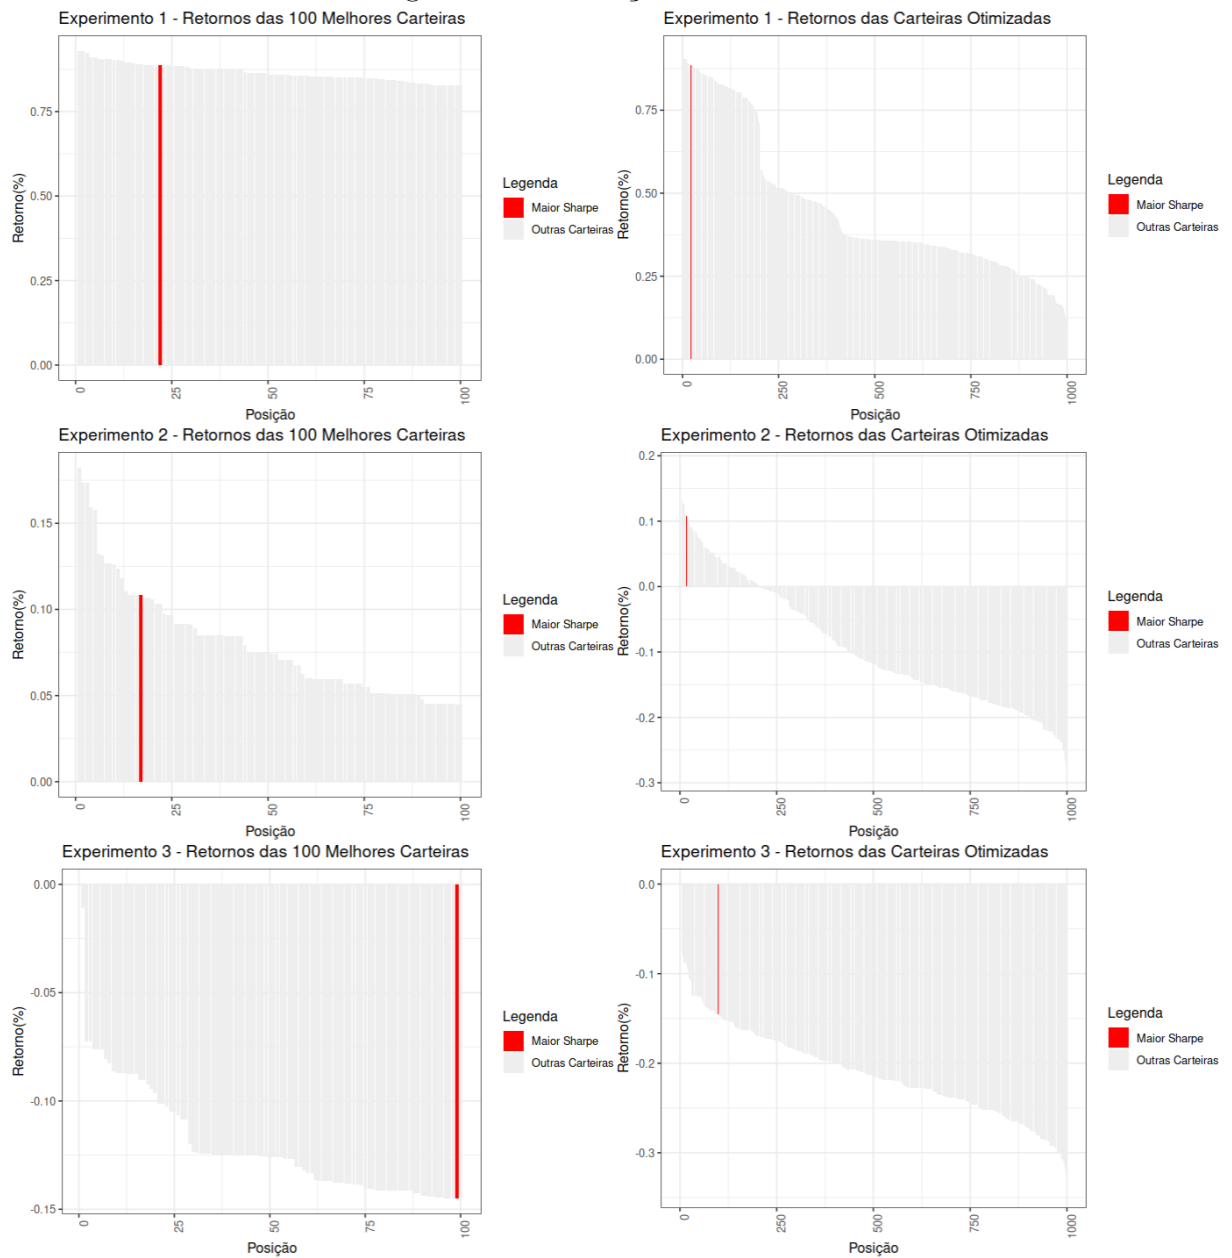
- a) Estar entre os 100 melhores retornos é um indicativo positivo, pois demonstra que a melhor carteira otimizada pelo CGA teve um desempenho superior a 90% em relação às outras carteiras do conjunto de teste. Além disso, o fato de a carteira estar entre os 100 melhores valida a escolha do índice Sharpe como métrica de avaliação da aptidão dos indivíduos.
- b) Esses retornos são considerados bons em relação às outras 999 carteiras, uma vez que estão acima da média e da mediana dos retornos das carteiras geradas, conforme apresentado na Tabela 8.
- c) Apesar de a melhor carteira não ter alcançado o primeiro lugar no conjunto de teste, os pesos estipulados pelo CGA asseguraram que ela ficasse entre os 100 melhores retornos. Essa observação destaca-se ao considerar a limitação do CGA em operar exclusivamente com representações binárias, o que implica na alocação igualitária de recursos entre os ativos.
- d) Considerando o perfil do investidor, a escolha entre investir em criptomoedas e optar pela poupança tradicional envolve uma análise cuidadosa das preferências e tolerância ao risco. O retorno a curto prazo das criptomoedas pode ser potencialmente maior, mas esse cenário está intrinsecamente associado a um nível de risco mais elevado, característico do mercado volátil das criptomoedas. Em contrapartida, a poupança oferece um retorno mais estável, com uma taxa tradicional fixa. A poupança é uma alternativa mais conservadora, proporcionando estabilidade e previsibilidade nos ganhos, o que pode ser particularmente atraente para investidores que buscam preservar o capital com menor exposição a flutuações de mercado.

Tabela 8 – Estatísticas descritivas dos retornos das 1000 carteiras

<b>Experimento</b>	<b>Média</b>	<b>Mediana</b>	<b>Melhor Retorno</b>	<b>Menor Retorno</b>
1	0.45%	0.36%	0.93%	0.08%
2	-0.09%	-0.12%	0.18%	-0.29%
3	-0.21%	-0.21%	-0.01%	-0.34%

Fonte: Elaborado pelo autor, 2023

Figura 19 – Avaliação das carteiras



Fonte: Elaborado pelo autor, 2023

## 6 CONCLUSÃO

Nesta monografia, foi proposta uma modelagem para a otimização de carteiras de criptomoedas por meio do CGA, utilizando como base a Teoria Moderna de Portfólio de Markowitz. A abordagem desse tema foi motivada pelo cenário atual do mercado financeiro, caracterizado pela constante evolução e pelo sucesso das criptomoedas, as quais têm se estabelecido como uma alternativa de investimento em crescimento nos últimos anos.

Inicialmente, estabeleceu-se uma base sólida para o entendimento das técnicas empregadas. Exploraram-se os fundamentos, abrangendo o mercado de criptomoedas, a tecnologia *blockchain* e volatilidade desse mercado. Em relação aos conceitos estatísticos, foram detalhados o desvio-padrão, covariância e correlação, que ajudaram na compreensão das métricas de risco e retorno das carteiras. No campo das finanças, foi apresentada a Teoria de Markowitz, que estabelece as bases para a construção de carteiras de investimento e o índice Sharpe que avalia as carteiras geradas. E, na área de otimização computacional, foi empregado o CGA. Com a revisão bibliográfica pôde-se notar que essa é uma área ainda pouco explorada.

Adicionalmente, foi analisada a influência da correlação entre os ativos que compõem as carteiras, uma importante limitação da Teoria de Markowitz. Durante a análise do coeficiente de correlação, foi notada uma tendência em direção a uma correlação positiva próxima de 1, o que ilustra o comportamento característico do mercado de criptomoedas. Esta alta correlação positiva é uma barreira para a diversificação de carteiras, uma vez que a Teoria de Markowitz pressupõe uma correlação negativa ou baixa entre ativos para a construção eficaz de carteiras diversificadas.

Os dados históricos coletados abrangeram um período de três anos (2020 a 2022). Esses dados foram divididos em três experimentos distintos para avaliar o desempenho das carteiras. No primeiro experimento, a principal carteira alcançou a 22<sup>o</sup> posição entre 1000 no conjunto de teste, obtendo um retorno de 0.89% em relação ao valor investido. No segundo, a melhor carteira ficou classificada em 17<sup>o</sup>, com um retorno de 0.11%. E, no terceiro experimento, ficou em 99<sup>o</sup>, registrando um retorno negativo de -0.14%. Esses resultados demonstram que o CGA é capaz de otimizar as carteiras de forma a posicioná-las ao menos entre os 100 melhores retornos do período estudado entre 1000, conforme definido na métrica de avaliação. Apesar de obter um retorno negativo, é importante destacar que a carteira otimizada pelo CGA ainda se manteve dentro do intervalo estipulado. Isso indica que o desempenho dessa carteira reflete mais as condições do mercado de criptomoedas do que a eficácia do CGA em si.

Em relação às limitações da solução proposta, destacam-se:

- a) Correlação forte entre os ativos: a forte correlação entre os ativos representa um desafio significativo. Essa interdependência pode limitar a capacidade do algoritmo



de proporcionar uma melhor diversificação.

- b) Volatilidade do mercado de criptomoedas: A volatilidade desse mercado pode ser influenciada por fatores como oferta e demanda, atratividade dos investidores, anonimato dos usuários e incertezas políticas e econômicas, tornando a previsão de movimentações de preços uma tarefa desafiadora. O desenvolvimento de uma ferramenta capaz de prever com precisão essas mudanças ainda é um dos desafios dessa área de pesquisa.
- c) Limitação do CGA: O algoritmo é capaz apenas de encontrar soluções com pesos iguais para os ativos, o que pode ser percebido como uma restrição que compromete a diversificação das carteiras.

Para trabalhos futuros, é recomendável explorar estratégias adicionais para lidar com a forte correlação entre os ativos. A escolha de ativos com baixa correlação ao compor as carteiras de criptomoedas pode ser uma abordagem eficaz para mitigar essa limitação. Quanto à restrição do CGA em encontrar soluções com pesos iguais para os ativos, sugere-se investigar maneiras de diversificar a distribuição dos pesos. Além disso, para uma compreensão mais aprofundada do desempenho da solução desenvolvida, é desejável realizar análises comparativas entre o CGA e outras formas de otimização de portfólio.

## REFERÊNCIAS

- AJAO, L. A. *et al.* Crypto hash algorithm-based blockchain technology for managing decentralized ledger database in oil and gas industry. **J**, v. 2, n. 3, p. 300–325, 2019. DOI: 10.3390/j2030021. Acesso em: 23 ago. 2023.
- BERNARDO, M. Â. V. d. F. F. **Comparação do mercado de criptomoedas com os mercados de ativos tradicionais**. 2022. Dissertação de Mestrado – Universidade de Évora. Disponível em: <http://hdl.handle.net/10174/32711>. Acesso em: 2 mai. 2023.
- BREALEY, R. A.; MYERS, S. C.; ALLEN, F. **Princípios de Finanças Corporativas**. 10ª ed. Porto Alegre: AMGH Editora, 2013.
- COCCO, L.; CONCAS, G.; MARCHESI, M. Using an artificial financial market for studying a cryptocurrency market. **Journal of Economic Interaction and Coordination**, Springer, v. 12, p. 345–365, 2017.
- COINMARKETCAP. **Top 100 Criptomoedas por Capitalização de Mercado**. 2023. Disponível em: <https://coinmarketcap.com/pt-br/>. Acesso em: 15 mai. 2023.
- DA SILVA, R. R. **Estudo e aplicação de um algoritmo genético compacto usando elitismo e mutação**. 2008. Dissertação de Mestrado – Universidade Tecnológica Federal do Paraná, Curitiba.
- DIAS, C. H. **Um novo algoritmo genético para a otimização de carteiras de investimento com restrições de cardinalidade**. 2008. Dissertação de Mestrado – Departamento de Matemática Aplicada, Universidade Estadual de Campinas. Disponível em: <https://www.ime.unicamp.br/~chico/papers/mestradocarlos.pdf>. Acesso em: 19 abr. 2023.
- EUREX. **Eurex provides investors a trusted path to crypto**. 2021. Disponível em: <https://www.eurex.com/ex-en/find/news/eurex-bitcoin-webcast-2846752>. Acesso em: 20 abr. 2023.
- FARIAS, A. M. L. **Variáveis Aleatórias Bidimensionais**. 2020. Departamento de Estatística - UFF. Niterói.
- GOOGLE BOOKS. **Google Ngram Viewer**. 2023. Disponível em: <https://bit.ly/3NMJ9A2>. Acesso em: 15 mai. 2023.
- GUIMARÃES, P. R. B. **Análise de Correlação e medidas de associação**. 2017. Universidade Federal do Paraná. Curitiba, p. 1-26.
- HÄRDLE, W. K.; HARVEY, C. R.; REULE, R. C. Understanding cryptocurrencies. **Journal of Financial Econometrics**, v. 18, n. 2, p. 181–208, 2020.
- HARIK, G. R.; LOBO, F. G.; GOLDBERG, D. E. The compact genetic algorithm. **IEEE Transactions on Evolutionary Computation**, v. 3, n. 4, p. 287–297, 1999. DOI: 10.1109/4235.797971.
- HOLLAND, J. H. **Adaptation in Natural and Artificial Systems**. University of Michigan Press, Ann Arbor, 1975. v. 7, p. 390–401.

LACERDA, D. P. *et al.* Design Science Research: método de pesquisa para a engenharia de produção. **Gestão & Produção**, v. 20, p. 741–761, 2013. Disponível em: <https://doi.org/10.1590/S0104-530X2013005000014>. Acesso em: 25 mai. 2023.

LAZO, J. G. L. *et al.* Sistema híbrido para tomada de decisão em investimentos no mercado de criptomoedas. **Brazilian Journal of Development**, v. 7, n. 2, p. 19577–19593, 2021. Disponível em: <https://ojs.brazilianjournals.com.br/ojs/index.php/BRJD/article/view/25249>. Acesso em: 20 abr. 2023.

LO, A. W. The Statistics of Sharpe Ratios. **Financial Analysts Journal**, v. 58, n. 4, p. 36–52, 2002. DOI: 10.2469/faj.v58.n4.2453. Acesso em: 15 set. 2023.

MAGALHÃES, W. **Ativos financeiros: descubra o que são e se vale a pena investir**. Acesso em: 28 ago. 2023. 2022. Disponível em: <https://www.remessaonline.com.br/blog/ativos-reais-e-ativos-financeiros-voce-conhece-esses-termos/>.

MALLQUI, D. C.; FERNANDES, R. A. Predicting the direction, maximum, minimum and closing prices of daily Bitcoin exchange rate using machine learning techniques. **Applied Soft Computing**, v. 75, p. 596–606, 2019.

MANGRAM, M. E. A simplified perspective of the Markowitz portfolio theory. **Global Journal of Business Research**, v. 7, n. 1, p. 59–70, 2013. Disponível em: <https://ssrn.com/abstract=2147880>. Acesso em: 18 ago. 2023.

MARKOWITZ, H. Portfolio Selection\*. **The Journal of Finance**, v. 7, n. 1, p. 77–91, mar. 1952.

MARQUES, F. T. **Otimização de carteiras com lotes de compra e custos de transação, uma abordagem por algoritmos genéticos**. 2007. Dissertação (Mestrado em Engenharia de Produção) – Escola de Engenharia de São Carlos, Universidade de São Paulo, São Carlos. DOI: 10.11606/D.18.2007.tde-10122007-214030. Disponível em: <https://doi.org/10.11606/D.18.2007.tde-10122007-214030>. Acesso em: 20 abr. 2023.

NAKAMOTO, S. Bitcoin: A peer-to-peer electronic cash system. **Decentralized Business Review**, p. 21260, 2008.

NOFER, M. *et al.* Blockchain. **Business & Information Systems Engineering**, v. 59, p. 183–187, 2017. DOI: 10.1007/s12599-017-0467-3. Acesso em: 9 jul. 2023.

NOGUEIRA, H. V. **Algoritmo genético compacto com dominância para seleção de variáveis**. 2017. Dissertação (Mestrado em Ciência da Computação) – Universidade Federal de Goiás, Goiânia. Disponível em: <http://repositorio.bc.ufg.br/tede/handle/tede/7360>. Acesso em: 20 abr. 2023.

PEFFERS, K. *et al.* A design science research methodology for information systems research. **Journal of Management Information Systems**, v. 24, n. 3, p. 45–77, 2007. DOI: 10.2753/MIS0742-1222240302. Acesso em: 26 mai. 2023.

POZO, A. *et al.* **Computação evolutiva**. 2005. p. 61. Disponível em: <https://www.inf.ufpr.br/aurora/tutoriais/Ceapostila.pdf>. Acesso em: 20 abr. 2023.

PRESSMAN, R. S.; MAXIM, B. R. **Engenharia de Software-9**. McGraw Hill Brasil, 2021.

ROUDIER, F. Portfolio optimization and genetic algorithms. **Master's thesis, Department of Management, Technology and Economics, Swiss Federal Institute of Technology (ETM), Zurich**, 2007.

SAMANEZ, C. P. M. **Gestão de Investimentos e Geração de Valor**. E-book. São Paulo: Pearson, 2007. Disponível em: <https://plataforma.bvirtual.com.br>. Acesso em: 14 set. 2023.

SCHMIDT, M. **How Risk-Free Is the Risk-Free Rate of Return**. Investopedia. 2023. Disponível em: <https://www.investopedia.com/articles/financial-theory/08/risk-free-rate-return.asp>. Acesso em: 31 out. 2023.

SICHEL, R. L.; CALIXTO, S. R. Criptomoedas: impactos na economia global. Perspectivas / Cryptocurrency: impacts in the global economy. Perspectives. **Revista de Direito da Cidade**, v. 10, n. 3, p. 1622–1641, ago. 2018. ISSN 2317-7721. Disponível em: <https://www.e-publicacoes.uerj.br/index.php/rdc/article/view/33096>. Acesso em: 20 abr. 2023.

STREICHERT, F.; ULMER, H.; ZELL, A. Evaluating a hybrid encoding and three crossover operators on the constrained portfolio selection problem. In: PROCEEDINGS of the 2004 Congress on Evolutionary Computation (IEEE Cat. No.04TH8753). 2004. v. 1, p. 932–939 Vol.1. DOI: 10.1109/CEC.2004.1330961.

TREDINNICK, L. Cryptocurrencies and the blockchain. **Business Information Review**, v. 36, n. 1, p. 39–44, 2019.

ULRICH, F. **Bitcoin: a moeda na era digital**. 1. ed. São Paulo: LVM Editora, 2014.

WAZLAWICK, R. S. **Metodologia de pesquisa para ciência da computação**. Elsevier, 2009.

XU, R.-t. *et al.* An Estimation of Distribution Algorithm Based Portfolio Selection Approach. In: IEEE. 2010 International Conference on Technologies and Applications of Artificial Intelligence. 2010. p. 305–313.

YIN, L.; NIE, J.; HAN, L. Understanding cryptocurrency volatility: The role of oil market shocks. **International Review of Economics & Finance**, v. 72, p. 233–253, 2021.

ZAPP, L. **Otimização de carteiras de investimentos utilizando algoritmo evolutivo multiobjetivo**. 2022. Trabalho de Conclusão de Curso (Ciências da Computação) - Universidade Federal de Santa Catarina. Disponível em: <https://repositorio.ufsc.br/handle/123456789/232985>. Acesso em: 20 abr. 2023.